การวิเคราะห์ความรู้สึกข้อความภาษาไทยที่มีต่อบริการของโบรกเกอร์จากกระทู้พันทิปโดยใช้เทคนิคการเรียนรู้ของเครื่อง

นายธนภัทร วิริยะเกียรติไพศาล

นางสาวชญานันท์ สาระวิถี

นายพรภวิษย์ เคารพไทย

โครงงานนี้เป็นส่วนหนึ่งของการศึกษาตามหลักสูตร

ปริญญาวิทยาศาสตรบัณฑิต สาขาวิชาสถิติ

ภาควิชาคณิตศาสตร์ คณะวิทยาศาสตร์

มหาวิทยาลัยเทคโนโลยีพระจอมเกล้าธนบุรี

ปีการศึกษา 2567

Sentiment Analysis of Thai Text Regarding Broker Services on Pantip Using Machine Learning

Mr.Thanapat Wiriyakiatphaisan

Ms.Chayanan Saravithi

Mr.Pornpavit Kaoropthai

A PROJECT SUBMITTED PARTIAL FULFILLMENT OF THE REQUIREMENT

FOR THE BACHELOR DEGREE OF SCIENCE (STATISTICS)

DEPARTMENT OF MATHEMATICS FACULTY OF SCIENCE

KING MONGKUT'S UNIVERSITY OF TECHNOLOGY THONBURI 2024

การวิเคราะห์ความรู้สึกข้อความภาษาไทยที่มีต่อบริการของโบรกเกอร์
จากกระทู้พันทิปโดยใช้เทคนิคการเรียนรู้ของเครื่อง

นายธนภัทร	วิริยะเกียรติไพศาล	วท.บ. (สถิติ)
นางสาวชญานันท์	สาระวิถี	วท.บ. (สถิติ)
นายพรภวิษย์	เคารพไทย	วท.บ. (สถิติ)

โครงงานนี้เป็นส่วนหนึ่งของการศึกษาตามหลักสูตร
ปริญญาวิทยาศาสตรบัณฑิต สาขาวิชาสถิติ
ภาควิชาคณิตศาสตร์ คณะวิทยาศาสตร์
มหาวิทยาลัยเทคโนโลยีพระจอมเกล้าธนบุรี
ปีการศึกษา 2567

คณะกรรมการสอบโครงงาน

..... อาจารย์ที่ปรึกษาโครงงาน
(ผศ. ดร.ณรรฐคุณ วิรุฬห์ศรี)

..... กรรมการ
(รศ.ชูเกียรติ วรสุชีพ)

..... กรรมการ
(ผศ.ดร.ณภัทณ์จันทร์ ด่านสวัสดิ์)

..... กรรมการ
(ดร.พรทิพย์ เดชพิชัย)

..... กรรมการ
(ดร.ธเนศ จิตต์สุภาพรรณ)

ลิขสิทธิ์ของมหาวิทยาลัยเทคโนโลยีพระจอมเกล้าธนบุรี

หัวข้อวิทยานิพนธ์	การวิเคราะห์ความรู้สึกข้อความภาษาไทยที่มีต่อบริการของโบรกเกอร์จากกระทู้พันทิปโดยใช้เทคนิคการเรียนรู้ของเครื่อง
หน่วยกิต	3
ผู้เขียน	นายธนภัทร วิริยะเกียรติไพศาล
	นางสาวชญานันท์ สาระวิถี
	นายพรภวิษย์ เคารพไทย
อาจารย์ที่ปรึกษา	ผศ. ดร.ณรรฐคุณ วิรุฬห์ศรี
หลักสูตร	วิทยาศาสตรบัณฑิต
สาขาวิชา	สถิติ
ภาควิชา	คณิตศาสตร์
คณะ	วิทยาศาสตร์
ปีการศึกษา	2567

บทคัดย่อ

งานวิจัยนี้มีวัตถุประสงค์เพื่อวิเคราะห์และแบ่งประเภทหัวข้อและจำแนกความรู้สึกจากข้อความแสดงความคิดเห็นภาษาไทยที่มีต่อบริการของโบรกเกอร์บนเว็บบอร์ด Pantip.com โดยใช้เทคนิคการประมวลผลภาษาธรรมชาติและการเรียนรู้ของเครื่อง จากข้อมูลความคิดเห็น 1,327 ข้อความ ได้ถูกจำแนกออกเป็น 5 ประเภทหัวข้อหลัก (ปัญหาทางระบบ, ค่าธรรมเนียม, การบริการ, การเทรด, และอื่น ๆ) ด้วยวิธีการแบบอิงกฎ พบว่าประเด็น การเทรด (62.02%) และ การบริการ (28.41%) ถูกกล่าวถึงมากที่สุด จากนั้น ข้อความได้ถูกนำมาจำแนกระดับความรู้สึก (บวก, กลาง, ลบ) โดยใช้แบบจำลอง Lasso Logistic Regression ร่วมกับเทคนิค TF-IDF บนชุดข้อมูลที่ผ่านการทำ Under sampling (909 ข้อความแบ่งเป็นชุดฝึกสอน 727 และชุดทดสอบ 182 ข้อความ) ผลการประเมินแบบจำลองบนชุดข้อมูลทดสอบให้ค่าความแม่นยำโดยรวม (Overall Accuracy) ประมาณ 73.08% โดยมีประสิทธิภาพดีที่สุดในการจำแนกความคิดเห็นเชิงบวก (F1-score 0.84) ตามด้วยเชิงลบและที่เป็นกลาง (F1-score 0.67 เท่ากัน) การวิเคราะห์ระดับความรู้สึกในแต่ละประเภทหัวข้อชี้ว่าผู้ใช้งานแสดงความรู้สึกเชิงลบต่อ ปัญหาทางระบบ และเชิงบวกต่อ การบริการ ขณะที่ การเทรด มีความรู้สึกที่หลากหลาย ผลการวิจัยนี้ให้ข้อมูลเชิงลึกที่เป็นประโยชน์ต่อผู้ให้บริการโบรกเกอร์ในการทำความเข้าใจและปรับปรุงบริการ พร้อมทั้งเสนอแนะแนวทางการพัฒนางานวิจัยในอนาคตเพื่อเพิ่มประสิทธิภาพและความสามารถในการวิเคราะห์

คำสำคัญ: การวิเคราะห์ข้อความ, การประมวลผลภาษาธรรมชาติ, เทคนิคการเรียนรู้แบบมีผู้สอน

Thesis Title	Sentiment Analysis of Thai Text Regarding Broker Services on Pantip Using Machine Learning
Thesis Credits	3
Candidate	Mr.Thanapat Wiriyakiatphaisan Ms.Chayanan Saravithi Mr.Pornpavit Kaoropthai
Thesis Advisors	Asst. Prof. Dr. Nathakhun Wiroonsri
Program	Bachelor of Science
Field of Study	Statistics
Department	Mathematics
Faculty	Science
Academic Year	2024

Abstract

This research aims to analyze, categorize topics, and classify sentiment from Thai language comments regarding broker services on the pantip.com webboard, utilizing natural language processing and machine learning techniques. From 1,327 comment messages, they were classified into five topics categories (system issues, fees, service, trading, and others) using a rule-based method. It was found that 'trading' (62.02%) and 'service' (28.41%) were the most mentioned topics. Subsequently, the messages were classified by sentiment level (Positive, Neutral, Negative) using a lasso logistic regression model combined with TF-IDF for feature extraction on an under sampled dataset (909 samples, divided into 727 training and 182 test samples). The model evaluation on the test dataset yielded an overall accuracy of approximately 73.08%, with the best performance in classifying positive comments (F1-score 0.84), followed by negative and neutral comments (F1-score 0.67 for both). Sentiment analysis within each topic category indicated that users expressed negative sentiment towards 'system Issues' and positive sentiment towards 'service', while 'trading' exhibited mixed sentiments. The results of this research provide valuable insights for brokerage service providers to understand and improve their services, along with suggesting future research directions to enhance analytical efficiency and capabilities.

Keywords**:** Text Analysis, Natural Language Processing, Supervised Learning Techniques

กิตติกรรมประกาศ

วิทยานิพนธ์ฉบับนี้สำเร็จลุล่วงได้ด้วยดี ผู้จัดทำขอขอบพระคุณบุคคลและหน่วยงานต่าง ๆ ที่ได้ให้คำปรึกษา คำแนะ ความอนุเคราะห์ ช่วยเหลือ และให้การสนับสนุนเป็นอย่างดียิ่ง ดังนี้

ขอขอบพระคุณ ผศ. ดร.ณรรฐคุณ วิรุฬห์ศรี อาจารย์ที่ปรึกษาโครงงานวิจัย ที่ได้กรุณาให้คำปรึกษา แนะนำแนวทางการดำเนินงานวิจัย ชี้แนะประเด็นสำคัญ รวมถึงตรวจสอบและแก้ไขข้อบกพร่องต่าง ๆ ด้วยความเอาใจใส่เสมอมา จนกระทั่งโครงงานวิจัยฉบับนี้สำเร็จสมบูรณ์ ผู้จัดทำรู้สึกซาบซึ้งในความเมตตาของท่านเป็นอย่างยิ่ง

ขอขอบพระคุณคณาจารย์ภาควิชาคณิตศาสตร์ คณะวิทยาศาสตร์ มหาวิทยาลัยเทคโนโลยีพระจอมเกล้าธนบุรี ทุกท่าน ที่ได้ประสิทธิ์ประสาทวิชาความรู้และประสบการณ์อันเป็นประโยชน์ยิ่งต่อการทำโครงงานวิจัยนี้

ขอขอบคุณเว็บไซต์ Pantip.com ที่เป็นแหล่งข้อมูลสำคัญในการรวบรวมข้อความแสดงความคิดเห็นเพื่อนำมาใช้ในการวิเคราะห์ครั้งนี้ รวมถึงผู้แสดงความคิดเห็นทุกท่านที่ได้แบ่งปันข้อมูลอันเป็นประโยชน์ต่องานวิจัย

ขอขอบคุณเพื่อน ๆ ในสาขาวิชาสถิติ สำหรับกำลังใจ ความช่วยเหลือ และการแลกเปลี่ยนความคิดเห็นที่เป็นประโยชน์ตลอดระยะเวลาการทำโครงงานวิจัย

ท้ายที่สุดนี้ ขอกราบขอบพระคุณ บิดา มารดา และครอบครัว ที่ได้ให้การสนับสนุนด้านกำลังทรัพย์ กำลังใจ และเป็นที่พึ่งทางใจเสมอมา ความสำเร็จของโครงงานวิจัยฉบับนี้ส่วนหนึ่งมาจากความรักและความเข้าใจของครอบครัว ขอขอบพระคุณเป็นอย่างสูง

นายธนภัทร วิริยะเกียรติไพศาล
นางสาวชญานันท์ สาระวิถี
นายพรภวิษย์ เคารพไทย

สารบัญ

หน้า

บทคัดย่อ (ภาษาไทย) ..... **ก**

บทคัดย่อ (ภาษาอังกฤษ) ..... **ข**

กิตติกรรมประกาศ ..... **ค**

สารบัญ ..... **ง**

สารบัญตาราง ..... **ฉ**

สารบัญรูปภาพ ..... **ช**

บทที่ 1 บทนำ **1**

1.1 ความสำคัญและที่มาของงานวิจัย 1

1.2 วัตถุประสงค์ของงานวิจัย 1

1.3 ประโยชน์และผลที่คาดว่าจะได้รับจากงานวิจัย 2

1.4 ขอบเขตงานวิจัย 2

1.5 ขั้นตอนการดำเนินงาน 2

1.6 นิยามศัพท์เฉพาะ 3

บทที่ 2 ทฤษฎีและงานวิจัยที่เกี่ยวข้อง **4**

2.1 ทฤษฎีที่ใช้ในงานวิจัย 4

2.2 งานวิจัยที่เกี่ยวข้อง 11

บทที่ 3 การดำเนินงานวิจัย **15**

3.1 การออกแบบกระบวนการและวิธีการดำเนินการวิจัย 15

3.2 การเก็บรวบรวมข้อมูล 15

3.3 การเตรียมความพร้อมของข้อมูล (Data Preparation) 17

3.4 การแบ่งกลุ่มข้อมูล (Category Classification) 20

3.5 การวิเคราะห์ความรู้สึก (Sentiment Analysis) 20

3.6 การประเมินผลแบบจำลอง 23

สารบัญ (ต่อ)

บทที่ 4 ผลการดำเนินงานวิจัย.....24

4.1 ผลลัพธ์ของการแบ่งประเภทของข้อความ จำนวน 5 ประเภท จากข้อความของการแสดงความคิดเห็น ปัญหาทางระบบ ค่าธรรมเนียม การบริการ การเทรด และอื่น ๆ.....24

4.2 ผลลัพธ์ของการประเมินประสิทธิภาพแบบจำลอง Lasso Logistic Regression ในการจำแนกความรู้สึก.....25

4.3 ระดับความรู้สึกในแต่ละประเภทหัวข้อความคิดเห็น.....26

บทที่ 5 สรุปผลการวิจัย อภิปรายผล และข้อเสนอแนะ.....30

5.1 สรุปผลการวิจัย.....30

5.2 อภิปรายผลการวิจัย.....31

5.3 ข้อเสนอแนะ.....32

เอกสารอ้างอิง.....33

ภาคผนวก ก.....35

สารบัญตาราง

หน้า

ตารางที่ 2.1 สรุปงานวิจัยที่เกี่ยวข้องที่สำคัญ 14

ตารางที่ 3.1 ตัวอย่างชุดคำหลักสำหรับการแบ่งกลุ่มข้อความ 20

ตารางที่ 4.1 แสดงผลลัพธ์ของการแบ่งประเภทของข้อความ จำนวน 5 ประเภท ด้วย Rule-based keyword matching 24

ตารางที่ 4.2 แสดงตัวอย่างการแบ่งประเภทข้อความ 25

ตารางที่ 4.3 แสดงตาราง Classification Report การประเมินผลลัพธ์การทำนายตัวแบบ 25

สารบัญรูปภาพ

หน้า

ภาพประกอบที่ 2.1 ขอบเขตศาสตร์ความรู้ของ Machine Learning 4
ภาพประกอบที่ 2.2 Logistic Regression 8
ภาพประกอบที่ 2.3 Lasso Logistic Regression 9
ภาพประกอบที่ 2.4: Confusion Matrix 10
ภาพประกอบที่ 3.1 แสดงกระบวนการดำเนินงานวิจัย 15
ภาพประกอบที่ 3.2 แสดงขั้นตอนการดึงข้อมูลจากเว็บไซต์ 15
ภาพประกอบที่ 3.3 แสดงตัวอย่างหน้าจอเว็บไซต์ *www.pantip.com* 16
ภาพประกอบที่ 3.4 แสดงตัวอย่างชุดข้อมูล 16
ภาพประกอบที่ 3.5 แสดงจำนวนข้อมูลของแต่ละความรู้สึก 17
ภาพประกอบที่ 3.6 แสดงตัวอย่างชุดข้อมูลหลังระบุ Label 17
ภาพประกอบที่ 3.7 แสดงขั้นตอนการทำความสะอาดข้อความ 18
ภาพประกอบที่ 3.8 แสดงตัวอย่างการสร้างกลุ่มคำที่ปรากฏอยู่ในความรู้สึกของข้อความเป็น บวก 19
ภาพประกอบที่ 3.9 แสดงตัวอย่างการสร้างกลุ่มคำที่ปรากฏอยู่ในความรู้สึกของข้อความเป็น กลาง 19
ภาพประกอบที่ 3.10 แสดงตัวอย่างการสร้างกลุ่มคำที่ปรากฏอยู่ในความรู้สึกของข้อความเป็น ลบ 19
ภาพประกอบที่ 3.11 แสดงจำนวนข้อมูลหลังจากการทำ under sampling 20
ภาพประกอบที่ 3.12 แสดงขั้นตอน และตัวอย่างคุณสมบัติจากการคำนวณ TF-IDF 21
ภาพประกอบที่ 3.13 แสดงข้อมูลหลังจากการทำการแบ่งชุดข้อมูล 22
ภาพประกอบที่ 4.1 แสดงตาราง Confusion Matrix การประเมินผลลัพธ์การทำนายตัวแบบ 26
ภาพประกอบที่ 4.2 แสดงผลลัพธ์ด้านการเทรด 27
ภาพประกอบที่ 4.3 แสดงผลลัพธ์ด้านการบริการ 27
ภาพประกอบที่ 4.4 แสดงผลลัพธ์ด้านค่าธรรมเนียม 28
ภาพประกอบที่ 4.5 แสดงผลลัพธ์ด้านอื่นๆ 28
ภาพประกอบที่ 4.6 แสดงผลลัพธ์ด้านระบบ 29

บทที่ 1
บทนำ

1.1 ความสำคัญและที่มาของงานวิจัย

ในยุคปัจจุบันที่ข้อมูลดิจิทัลมีบทบาทสำคัญอย่างยิ่งต่อพฤติกรรมผู้บริโภคและการตัดสินใจด้านการลงทุน เสียงสะท้อนของผู้ใช้บริการที่เผยแพร่ผ่านแพลตฟอร์มออนไลน์ เช่น เว็บบอร์ด “ Pantip” กลายเป็นแหล่งข้อมูลสำคัญที่สามารถนำมาวิเคราะห์เพื่อประเมินความพึงพอใจ ความเชื่อมั่น หรือปัญหาที่เกิดขึ้นจากการใช้บริการของโบรกเกอร์ ซึ่งล้วนมีอิทธิพลต่อภาพลักษณ์ การตัดสินใจของนักลงทุน และแนวโน้มของตลาดในวงกว้าง

อย่างไรก็ตาม การวิเคราะห์ความคิดเห็นเหล่านี้ด้วยวิธีการทั่วไปอาจไม่สามารถจัดการกับลักษณะเฉพาะของข้อความภาษาไทย ซึ่งมีความซับซ้อนทางโครงสร้างและขาดการเว้นวรรคได้ดีเท่ากับภาษาอื่น นอกจากนี้ ข้อความที่ปรากฏในเว็บบอร์ดยังมีลักษณะหลากหลายทั้งในเชิงเนื้อหา น้ำเสียง และความตั้งใจ การนำเทคนิคด้านการประมวลผลภาษาธรรมชาติ (NLP) ร่วมกับเทคนิคการเรียนรู้ของเครื่อง (Machine Learning) จึงมีความจำเป็นอย่างยิ่งในการแปลงข้อความเหล่านี้ให้เป็นข้อมูลเชิงวิเคราะห์ที่ใช้งานได้จริง

งานวิจัยนี้จะมุ่งเน้นการ วิเคราะห์ความรู้สึกของข้อความ (Positive, Neutral, Negative) ของผู้ใช้งานต่อโบรกเกอร์ต่าง ๆ บนพันทิปโดยใช้ เทคนิค Lasso Logistic Regression ซึ่งมีความสามารถในการคัดเลือกคุณลักษณะที่สำคัญ (feature selection) ได้อย่างมีประสิทธิภาพ เหมาะสมกับลักษณะของข้อมูลข้อความที่มีจำนวนคำจำนวนมากแต่มีเพียงบางส่วนเท่านั้นที่มีนัยสำคัญต่อผลลัพธ์ และ แบ่งหมวดหมู่ของความคิดเห็นตามประเด็นต่าง ๆ ที่เกี่ยวข้องกับการบริการของโบรกเกอร์ เช่น ปัญหาทางระบบ ค่าธรรมเนียม การบริการ การเทรด และอื่น ๆ

ผลลัพธ์ที่ได้จะสามารถนำไปต่อยอดในการประเมินคุณภาพการให้บริการของโบรกเกอร์ในสายตาผู้บริโภค ช่วยให้หน่วยงานที่เกี่ยวข้องสามารถปรับกลยุทธ์ พัฒนาระบบ หรือสื่อสารกับกลุ่มเป้าหมายได้อย่างตรงจุด อีกทั้งยังเป็นกรณีศึกษาสำคัญในการประยุกต์ใช้เทคโนโลยี NLP และ Machine Learning กับข้อความภาษาไทยในบริบทจริงได้อย่างมีประสิทธิภาพ

1.2 วัตถุประสงค์ของงานวิจัย

เพื่อประเมินประสิทธิภาพแบบจำลองสำหรับการวิเคราะห์และจำแนกความรู้สึกของข้อความภาษาไทยที่มีต่อบริการของโบรกเกอร์จากกระทู้พันทิป โดยใช้เทคนิคการเรียนรู้ของเครื่อง

1.3 ประโยชน์และผลที่คาดว่าจะได้รับจากงานวิจัย

1. รูปแบบการเรียนรู้ของเครื่องสำหรับจำแนกความรู้สึกของข้อความภาษาไทยเกี่ยวกับบริการโบรกเกอร์ ออกเป็น 3 ประเภท ได้แก่ เชิงบวก เชิงลบ และเป็นกลาง
2. สามารถแบ่งประเภทของข้อความ จำนวน 5 ประเภท จากข้อความของการแสดงความคิดเห็น ปัญหาทางระบบ ค่าธรรมเนียม การบริการ การเทรด และอื่น ๆ
3. ผู้ให้บริการด้านการลงทุน และโบรกเกอร์ สามารถนำความคิดเห็น และข้อเสนอแนะจากผู้ใช้งานไปวิเคราะห์ และวางกลยุทธ์พัฒนาบริการให้ตอบโจทย์ความต้องการของผู้ใช้งาน

1.4 ขอบเขตงานวิจัย

งานวิจัยนี้มีขอบเขตอยู่ในการวิเคราะห์ความคิดเห็นที่เผยแพร่ในรูปแบบข้อความภาษาไทยจากเว็บไซต์พันทิปโดยเน้นเฉพาะกระทู้ และความคิดเห็นที่กล่าวถึงบริการของบริษัทนายหน้าซื้อขายหลักทรัพย์ (โบรกเกอร์) ในบริบทของประเทศไทย

ข้อมูลที่ใช้ในการวิจัยจะอยู่ในช่วงปี พ.ศ. 2566–2568 โดยมีการคัดเลือกข้อความที่มีความเกี่ยวข้องผ่านกระบวนการคัดกรองคำสำคัญ (keyword filtering) และขั้นตอน heuristic filtering เพื่อให้ได้เฉพาะข้อความที่มีเนื้อหาเกี่ยวข้องกับการใช้งานหรือประสบการณ์ของผู้ใช้บริการโบรกเกอร์จริง

ในการวิเคราะห์ข้อมูล งานวิจัยนี้จะมุ่งเน้นการ วิเคราะห์ความรู้สึกของข้อความ แบ่งออกเป็น 3 ระดับ ได้แก่ บวก กลาง และ ลบ โดยจะทำการแบ่งหมวดหมู่ของความคิดเห็น ออกเป็นกลุ่ม 5 กลุ่ม เช่น ปัญหาทางระบบ ค่าธรรมเนียม การบริการ การเทรด และอื่น ๆ

เทคนิคที่นำมาใช้ในงานวิจัยประกอบด้วย การประมวลผลภาษาธรรมชาติ (Natural Language Processing), การแปลงข้อความด้วย TF-IDF, การเลือกคุณลักษณะด้วย Lasso Logistic Regression และจะมีการประเมินผลด้วยเกณฑ์มาตรฐาน เช่น Accuracy, Precision, Recall และ F1 Score

1.5 ขั้นตอนการดำเนินงาน

1.5.1 การเก็บรวบรวมข้อมูล

ดึงข้อมูลความคิดเห็นจากเว็บไซต์พันทิปที่เกี่ยวข้องกับบริการของโบรกเกอร์ โดยใช้เทคนิค Web Scraping และคัดกรองเฉพาะข้อความภาษาไทยที่มีเนื้อหาสอดคล้องกับหัวข้อการศึกษา

1.5.2 การเตรียมข้อมูล (Preprocessing)

เริ่มต้นด้วยการอ่านข้อความและระบุ Label โดยสมาชิกภายในกลุ่ม จากนั้นทำความสะอาดข้อมูล (Data Cleaning) ได้แก่ การลบตัวเลขและอักขระพิเศษ การแบ่งคำ (Tokenization) ด้วยไลบรารี และการลบคำที่ไม่สื่อความหมาย (Remove Stop words) เพื่อให้ข้อความอยู่ในรูปแบบที่เหมาะสมต่อการวิเคราะห์

1.5.3 การวิเคราะห์ข้อมูล

1.5.3.1 การจำแนกหมวดหมู่ (Text Classification)

ผู้วิจัยกำหนดหมวดหมู่ความคิดเห็นเบื้องต้นใช้วิธีการแบบ Rule-based อ้างอิงจากชุดคำหลัก (keywords) ที่ได้มาจากรากศัพท์ของคำ

1.5.3.2 การวิเคราะห์ความรู้สึก (Sentiment Analysis)

ขั้นตอนนี้ใช้แบบจำลอง Machine Learning เพื่อประเมินโทนความรู้สึกของข้อความแต่ละข้อความว่าเป็นบวก กลาง หรือ ลบ โดยนำชุดข้อมูลที่ผ่านการจัดการแล้วมาใช้ฝึกและทดสอบแบบจำลอง

1.5.4 การสร้างและประเมินผลลัพธ์แบบจำลอง

ข้อมูลหลัง Under Sampling ถูกแบ่งเป็นชุดฝึก (Training Set) และชุดทดสอบ (Test Set) ในอัตราส่วน 80:20 แบบจำลอง ที่เลือกใช้คือ Lasso Logistic Regression และทำการปรับพารามิเตอร์ (Hyperparameter Tuning) ด้วย Stratified K-Fold Cross-Validation เพื่อหาค่าที่เหมาะสม จากนั้นฝึกซ้ำแบบจำลอง ด้วยข้อมูลทั้งชุด ก่อนนำไปทดสอบบนชุดทดสอบเพื่อประเมินประสิทธิภาพด้วย Accuracy, Precision, Recall และ F1-Score สรุปผลด้วย Confusion Matrix เพื่อแสดงความสามารถในการจำแนกแต่ละประเภท

1.5.5 การสรุปผลและจัดทำรายงานวิจัย

รวบรวมผลการศึกษา สรุปข้อค้นพบ และจัดทำรายงานวิจัยฉบับสมบูรณ์ รวมถึงเสนอแนะแนวทางการนำไปประยุกต์ใช้ และการพัฒนาต่อยอดในอนาคต

1.6 นิยามศัพท์เฉพาะ

Pantip (พันทิป) หมายถึง เว็บไซต์สาธารณะออนไลน์ที่ใหญ่และได้รับความนิยมในประเทศไทย เป็นแหล่งข้อมูลหลักที่ใช้ในการเก็บรวบรวมความคิดเห็นของผู้ใช้งานในงานวิจัยนี้

โบรกเกอร์ หมายถึง บริษัทหลักทรัพย์ หรือผู้ให้บริการด้านการลงทุน ที่ทำหน้าที่เป็นตัวกลางในการซื้อขายหลักทรัพย์ หน่วยลงทุน หรือให้บริการที่เกี่ยวข้องกับการลงทุน ให้แก่ผู้ใช้งาน

ความรู้สึกเชิงบวก (Positive Sentiment) หมายถึง ข้อความที่แสดงทัศนคติ ความพึงพอใจ หรือประสบการณ์ที่ดีต่อโบรกเกอร์หรือบริการที่เกี่ยวข้อง

ความรู้สึกเป็นกลาง (Neutral Sentiment) หมายถึง ข้อความที่ไม่แสดงทัศนคติเชิงบวกหรือเชิงลบอย่างชัดเจน มักเป็นการสอบถาม ให้ข้อมูล หรือกล่าวถึงข้อเท็จจริงทั่วไป

ความรู้สึกเชิงลบ (Negative Sentiment) หมายถึง ข้อความที่แสดงทัศนคติ ความไม่พึงพอใจ ปัญหาหรือประสบการณ์ที่ไม่ดีต่อโบรกเกอร์หรือบริการที่เกี่ยวข้อง

บทที่ 2
ทฤษฎีและงานวิจัยที่เกี่ยวข้อง

ในการวิจัยครั้งนี้ ผู้วิจัยได้ศึกษาเอกสารและงานวิจัยที่เกี่ยวข้องกับการวิเคราะห์ความรู้สึกของข้อความภาษาไทยเกี่ยวกับโบรกเกอร์จากกระทู้พันทิปและได้นำเสนอตามหัวข้อต่อไปนี้

2.1 ทฤษฎีที่ใช้ในงานวิจัย

2.2 งานวิจัยที่เกี่ยวข้อง

2.1 ทฤษฎีที่ใช้ในงานวิจัย

2.1.1 การเรียนรู้ด้วยเครื่อง (Machine Learning)

การเรียนรู้ของเครื่องเป็นพื้นฐานเกี่ยวกับการสกัดค่าจากชุดข้อมูลขนาดใหญ่เพื่อนำมาวิเคราะห์ในสิ่งที่สนใจ นำมาใช้กับการวิจัยโดยวางอัลกอริทึมให้แบบจำลอง หรือตัวแบบทำงานอัตโนมัติ ส่วนมากแรงจูงใจคือการสร้างอัลกอริทึมที่สามารถเลียนแบบหรือเพิ่มประสิทธิภาพการวิเคราะห์แทนมนุษย์หรือทางชีวภาพได้ ขอบเขตของการเรียนรู้ด้วยเครื่องรวบศาสตร์ของสถิติและความรู้ด้านแบบจำลองทางคณิตศาสตร์ เพื่อเน้นการคาดการณ์หรือพยากรณ์ในสิ่งที่สนใจ และนำไปใช้ประโยชน์ ปัจจุบันการเรียนรู้ของเครื่องยังเป็นส่วนหนึ่งของวิทยาการคอมพิวเตอร์ที่เกี่ยวข้องกับการประมวลผลข้อมูลขนาดใหญ่ (Large-scale information processing)

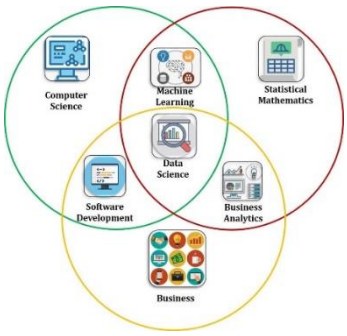

ภาพประกอบที่ 2.1 ขอบเขตศาสตร์ความรู้ของ Machine Learning

ที่มา: https://sjbit.edu.in/bachelor-of-engineering-in-computer-science-and-engineeringdata-science/

จากภาพรูปที่ 1 จะเห็นว่าการเรียนรู้ของเครื่องเป็นศาสตร์ร่วมของสถิติ คณิตศาสตร์ และวิทยาการคอมพิวเตอร์ โดยมีเทคนิคการวิเคราะห์มากมาย เทคนิคส่วนมากมีอัลกอรึทึมที่รับข้อมูลเข้ามาเรียนรู้

เทคนิค Machine Learning แบ่งออกเป็น 2 วิธี คือ

1) การเรียนรู้แบบมีผู้สอน (Supervised learning) เป็นเทคนิคที่เน้นเพื่อฝึกอัลกอริทึมให้ทำงานอย่างเฉพาะ โดยเรียนรู้จากชุดข้อมูลที่มีเป้าหมาย (Target) ที่แน่นอน

2) การเรียนรู้แบบไม่มีผู้สอน (Unsupervised learning) เป็นรูปแบบการเรียนรู้โดยที่ข้อมูลนำเข้า (Input) ทั้งหมดนั้นไม่มีการแบ่งประเภท และอัลกอริทึมต้องสร้างโครงสร้างจากข้อมูลนำเข้าด้วยตัวเอง เช่น การวิเคราะห์การจัดกลุ่ม (Cluster) เป็นการค้นหาการจัดกลุ่มภายในชุดข้อมูลนำเข้าหรือโครงข่ายประสาทเทียม (Neural networks) มีเป้าหมายเพื่อค้นหารูปแบบการอยู่รวมกันของข้อมูล

เทคนิคการเรียนรู้ของเครื่องแตกต่างจากการเขียนโปรแกรมทั่วไป การโปรแกรม (Programming) ปฏิบัติการโดยใส่ข้อมูล (Input data) และ ชุดคำสั่ง (Instruction set) ผ่านเข้ากระบวนการคำนวณ (Computing process) เพื่อให้ได้ผลลัพธ์ (Output) ในขณะที่การเรียนรู้ด้วยเครื่องปฏิบัติการโดยใส่ input และ output เข้ากระบวนการคำนวณ (Computing process) และเรียนรู้เพื่อหาฟังก์ชัน (Function) หรือตัวแบบ (Model) ที่เป็น Black-box หรือสมการ ที่จะนำไปใช้ตอบผลลัพธ์ในอนาคตได้ เมื่อผู้ใช้ใส่ข้อมูลนำเข้าใหม่เข้าตัวแบบรูปที่ 2 ข้อแตกต่างของแนวคิด และกระบวนการระหว่างการโปรแกรมกับการเรียนรู้ของเครื่อง

แนวคิดการเรียนรู้จากข้อมูล input และ output ที่ถูกป้อนเข้าไปนั้นพบว่าเป็นแนวคิดที่มีความแตกต่างระหว่างข้อมูลที่ใช้ในการฝึกหรือข้อมูลต้นแบบ (Train data) แบบจำลอง และข้อมูลที่ใช้ในทดสอบประสิทธิภาพของแบบจำลอง ที่ผ่านการฝึก (Test data) เนื่องจากมีข้อมูล 2 ชุดจากที่กล่าวมาพารามิเตอร์ของแบบจำลอง จะถูกตั้งค่าตามชุดข้อมูลที่ใช้ในการฝึกเท่านั้น ส่วนชุดข้อมูลที่ใช้ทดสอบถูกสร้างขึ้นจากกระบวนการที่มีรากฐานเดียวกันกับชุดข้อมูลที่ใช้ในการฝึก และค่าประมาณที่ไม่เอนเอียง (Unbiased estimate) ของประสิทธิภาพการทำงานสามารถรับได้โดยการวัดประสิทธิภาพข้อมูลที่ใช้ทดสอบของแบบจำลอง ที่ผ่านการฝึก ที่สำคัญประสิทธิภาพการทดสอบไม่ควรนำใช้เพื่อปรับพารามิเตอร์ของแบบจำลอง

2.1.2 การสกัดและดึงข้อมูลจากเว็บไซต์ (Web Scraping)

Web Scraping คือ กระบวนการที่ใช้เทคนิคทางโปรแกรมคอมพิวเตอร์ในการดึงข้อมูลจากเว็บไซต์โดยอัตโนมัติ โดยไม่ต้องทำการคัดลอกและวางข้อมูลด้วยตนเอง ซึ่งเป็นกระบวนการสำคัญในยุคของ Big Data และการวิเคราะห์ข้อมูลเชิงลึกจากแหล่งข้อมูลบนโลกออนไลน์ เช่น ข่าว, โพสต์บนโซเชียลมีเดีย, บทวิจารณ์สินค้า หรือความคิดเห็นของผู้ใช้ หลักการ คือ ทำงานโดยการส่งคำขอ (Request) ไปยังเว็บไซต์เป้าหมาย จากนั้นโปรแกรมจะได้รับข้อมูลตอบกลับในรูปแบบของ HTML ซึ่งเป็นโครงสร้างพื้นฐานของหน้าเว็บ แล้วจึงทำการ “แยกแยะข้อมูล” (Parse) ที่อยู่ในโครงสร้าง HTML นั้น เพื่อนำข้อมูลที่ต้องการออกมาเก็บไว้ในรูปแบบที่เหมาะสม เช่น CSV, JSON หรือฐานข้อมูล

2.1.3 การประมวลผลภาษาธรรมชาติ (Natural Language Processing – NLP)

การประมวลผลภาษาธรรมชาติ (Natural Language Processing: NLP) เป็นสาขาหนึ่งของปัญญาประดิษฐ์ (Artificial Intelligence: AI) ที่มุ่งเน้นการพัฒนาความสามารถของคอมพิวเตอร์ในการทำความเข้าใจ ตีความ และสร้างภาษามนุษย์ NLP มีบทบาทสำคัญอย่างยิ่งในการวิเคราะห์ความรู้สึก เนื่องจากช่วยให้สามารถสกัดความหมาย ความคิดเห็น และอารมณ์ ออกจากข้อมูลข้อความที่ไม่มีโครงสร้าง เช่น ข้อความในเว็บบอร์ดออนไลน์ การทำความเข้าใจภาษาธรรมชาติเกี่ยวข้องกับการวิเคราะห์ในหลายระดับ ตั้งแต่ระดับคำศัพท์ (lexical) การวิเคราะห์โครงสร้างประโยค (syntactic) ไปจนถึงการวิเคราะห์ความหมาย (semantic) ซึ่งล้วนเป็นพื้นฐานในการตีความเจตนาที่อยู่เบื้องหลังข้อความเพื่อให้คอมพิวเตอร์สามารถ “อ่าน” และ “เข้าใจ” ข้อความได้ จำเป็นต้องมีกระบวนการเตรียมข้อมูลข้อความเบื้องต้นหลายขั้นตอน ซึ่งเป็นงานพื้นฐานของ NLP ที่เกี่ยวข้องโดยตรงกับการวิเคราะห์ความรู้สึก ได้แก่

- การตัดคำ (Tokenization): เป็นกระบวนการแบ่งข้อความที่ยาว ออกเป็นหน่วยย่อย ๆ ที่เรียกว่า “โทเค็น” (token) ซึ่งโดยทั่วไปคือคำหรือวลี กระบวนการนี้เป็นขั้นตอนแรกที่สำคัญในการวิเคราะห์ข้อความภาษาไทย อย่างไรก็ตาม ภาษาไทยมีลักษณะเฉพาะที่ไม่มีการเว้นวรรคระหว่างคำอย่างชัดเจน ทำให้การตัดคำมีความท้าทายสูงกว่าภาษาอย่างภาษาอังกฤษ ความแม่นยำในการตัดคำจึงส่งผลกระทบโดยตรงต่อคุณภาพของขั้นตอนการวิเคราะห์ถัดไป เช่น การสกัดลักษณะเด่น (feature extraction)
- การกำกับชนิดของคำ (Part-of-Speech Tagging): เป็นการระบุหน้าที่ทางไวยากรณ์ของแต่ละคำในประโยค (เช่น คำนาม คำกริยา คำคุณศัพท์) ซึ่งช่วยในการทำความเข้าใจโครงสร้างและความหมายของประโยคได้ดียิ่งขึ้น
- การรู้จำชื่อเฉพาะ (Named Entity Recognition – NER): เป็นการระบุและจำแนกประเภทของชื่อเฉพาะในข้อความ เช่น ชื่อบุคคล ชื่อองค์กร (เช่น ชื่อโบรกเกอร์) สถานที่ หรือเวลา ซึ่งมีความสำคัญในการระบุเป้าหมายของความคิดเห็น
- การวิเคราะห์โครงสร้างประโยค (Parsing): เป็นการวิเคราะห์ความสัมพันธ์ทางไวยากรณ์ระหว่างคำต่างๆ ในประโยค เพื่อให้เข้าใจโครงสร้างและความหมายที่ซับซ้อนขึ้น

2.1.4 การแทนข้อความ: Term Frequency-Inverse Document Frequency (TF-IDF)

อัลกอริทึมการเรียนรู้ของเครื่องส่วนใหญ่ไม่สามารถประมวลผลข้อมูลข้อความดิบได้โดยตรง จำเป็นต้องมีการแปลงข้อความให้อยู่ในรูปแบบตัวเลขที่เรียกว่า “เวกเตอร์ลักษณะเด่น” (feature vector) เสียก่อน หนึ่งในเทคนิคที่ได้รับความนิยมและใช้กันอย่างแพร่หลายในการแทนข้อความคือ Term Frequency-Inverse Document Frequency (TF-IDF) ซึ่งเป็นวิธีการทางสถิติที่ใช้วัดความสำคัญของคำ (term) ในเอกสาร (document) หนึ่งชุด โดยพิจารณาจากความถี่ของคำนั้นในเอกสาร และความถี่ของคำนั้นในเอกสารทั้งหมดในคลังข้อมูล (corpus)

การคำนวณค่า TF-IDF ประกอบด้วยสองส่วนหลัก:

1. Term Frequency (TF): คือความถี่ของคำที่ปรากฏในเอกสาร แนวคิดพื้นฐานคือ คำที่ปรากฏบ่อยในเอกสาร มีแนวโน้มที่จะมีความสำคัญต่อเนื้อหาของเอกสารนั้นมากกว่าคำที่ปรากฏน้อยครั้ง การคำนวณ TF สามารถทำได้หลายวิธี เช่น การนับจำนวนครั้งที่คำปรากฏโดยตรง หรือการปรับค่าด้วยลอการิทึมเพื่อลดผลกระทบของคำที่ปรากฏบ่อยมากเกินไป

2. Inverse Document Frequency (IDF): คือค่าที่วัดว่าคำนั้นให้ข้อมูลมากน้อยเพียงใด หรือเป็นคำที่พบได้ทั่วไปหรือพบได้น้อยในเอกสารทั้งหมด คำที่ปรากฏในเอกสารจำนวนมาก (เช่น คำทั่วไปอย่าง ‘และ’, ‘คือ’, ‘ใน’) จะมีค่า IDF ต่ำ เนื่องจากไม่ช่วยในการจำแนกความแตกต่างระหว่างเอกสาร ในทางกลับกัน คำที่ปรากฏในเอกสารเพียงไม่กี่ฉบับ (เช่น คำศัพท์เฉพาะทาง) จะมีค่า IDF สูง เพราะถือว่าเป็นคำที่ให้ข้อมูลเฉพาะเจาะจงมากกว่า ค่า IDF คำนวณจากลอการิทึมของอัตราส่วนระหว่างจำนวนเอกสารทั้งหมดกับจำนวนเอกสารที่มีคำนั้นปรากฏอยู่

คะแนน TF-IDF (TF-IDF Score): คือผลคูณระหว่างค่า TF และค่า IDF ของคำนั้น ๆ คำที่มีคะแนน TF-IDF สูงคือคำที่ปรากฏบ่อยในเอกสาร เฉพาะฉบับนั้น แต่พบได้น้อยในเอกสารอื่น ๆ ทั้งหมดในคลังข้อมูล ซึ่งบ่งชี้ว่าคำนั้นมีความสำคัญและเป็นตัวแทนเนื้อหาของเอกสารนั้นได้ดี

2.1.5 การจัดการกับข้อมูลไม่สมดุล (Handling Imbalanced Data)

ปัญหาความไม่สมดุลของข้อมูล (Class Imbalance) เกิดขึ้นเมื่อจำนวนตัวอย่างของกลุ่มประเภท (class) หนึ่งในชุดข้อมูลฝึกสอนมีจำนวนแตกต่างกันอย่างมีนัยสำคัญเมื่อเทียบกับกลุ่มประเภทอื่นๆ ปัญหานี้พบได้บ่อยในข้อมูลจากโลกแห่งความเป็นจริง โดยเฉพาะอย่างยิ่งในการวิเคราะห์ความคิดเห็นจากโซเชียลมีเดีย ความไม่สมดุลของข้อมูลส่งผลกระทบอย่างมากต่อประสิทธิภาพของอัลกอริทึมการเรียนรู้ของเครื่องส่วนใหญ่ แบบจำลอง ที่ฝึกด้วยข้อมูลที่ไม่สมดุลมักจะมี ความเอนเอียงไปทางกลุ่มประเภทส่วนใหญ่ (majority class) และอาจได้ค่าความแม่นยำ (accuracy) โดยรวมสูงเพียงเพราะทำนายกลุ่มประเภทส่วนใหญ่ได้อย่างถูกต้อง แต่กลับมีประสิทธิภาพต่ำมากในการระบุตัวอย่างของกลุ่มประเภทส่วนน้อย (minority class) ซึ่งเป็นปัญหาใหญ่หากกลุ่มประเภทส่วนน้อย (เช่น ความคิดเห็นเชิงลบอย่างรุนแรง)

มีหลายกลยุทธ์ที่สามารถนำมาใช้เพื่อจัดการกับปัญหาข้อมูลที่ไม่สมดุล ได้แก่:

1. **แนวทางระดับข้อมูล (Data-Level Approaches):** มุ่งเน้นการปรับเปลี่ยนชุดข้อมูลฝึกสอนโดยตรงผ่านเทคนิคการสุ่มตัวอย่างใหม่ (Resampling):
   - **การสุ่มตัวอย่างเกิน (Oversampling):** เป็นการเพิ่มจำนวนตัวอย่างในกลุ่มประเภทส่วนน้อย เทคนิคที่นิยมใช้คือ SMOTE (Synthetic Minority Over-sampling Technique) ซึ่งแทนที่จะทำซ้ำตัวอย่างเดิม SMOTE จะสร้างตัวอย่างสังเคราะห์ (synthetic samples) ขึ้นมาใหม่ โดยพิจารณาจากตัวอย่างส่วนน้อยที่มีอยู่และเพื่อนบ้านที่ใกล้ที่สุด (nearest neighbors) ในปริภูมิลักษณะเด่น วิธีการ

นี้ช่วยเพิ่มความหลากหลายให้กับกลุ่มประเภทส่วนน้อยและลดความเสี่ยงของ Overfitting เมื่อเทียบกับการทำซ้ำแบบสุ่ม

- **การสุ่มตัวอย่างต่ำ (Under sampling):** เป็นการลดจำนวนตัวอย่างในกลุ่มประเภทส่วนใหญ่ วิธีนี้อาจช่วยให้ข้อมูลสมดุลขึ้นและลดเวลาในการฝึกแบบจำลอง แต่มีข้อเสียคืออาจทำให้สูญเสียข้อมูลสำคัญที่อยู่ในกลุ่มประเภทส่วนใหญ่ไป

2. แนวทางระดับอัลกอริทึม (Algorithmic-Level Approaches): เป็นการปรับเปลี่ยนอัลกอริทึมการเรียนรู้ให้คำนึงถึงความไม่สมดุลของข้อมูล เช่น Cost-Sensitive Learning ซึ่งกำหนดต้นทุน (cost) ที่แตกต่างกันสำหรับการจำแนกผิดพลาดในแต่ละกลุ่มประเภท (เช่น กำหนดต้นทุนสูงกว่าสำหรับการจำแนกตัวอย่างส่วนน้อยผิด)

3. แนวทางแบบผสม (Hybrid Approaches): เป็นการผสมผสานเทคนิค Oversampling และ Under sampling เข้าด้วยกัน

2.1.6 การถดถอยโลจิสติก (Logistic Regression)

การถดถอยโลจิสติก (Logistic Regression) เป็นวิธีทางสถิติที่ใช้สำหรับการจำแนกประเภทของข้อมูล โดยเฉพาะกรณีที่ตัวแปรตาม (Dependent Variable) มีลักษณะเป็นข้อมูลประเภทจำแนก (Categorical) หรือไบนารี เช่น การพยากรณ์ว่า “ใช่/ไม่ใช่”, “บวก/ลบ”, หรือ “ผ่าน/ไม่ผ่าน” เป็นต้น
ลักษณะเด่นของแบบจำลองนี้คือการใช้ Sigmoid Function ซึ่งมีสมการดังนี้

$$P(y=1|x) = \frac{1}{1+e^{-(\beta_0+\beta_1 x_1+\beta_2 x_2+\ldots+\beta_p x_p)}}$$

ภาพประกอบที่ 2.2 Logistic Regression

โดยที่ $\chi_1, \chi_2, \ldots, \chi_p$ คือ ตัวแปรอิสระ และ $\beta_1, \beta_2, \ldots\ldots, \beta_p$ คือสัมประสิทธิ์ของตัวแปร ซึ่งจะถูกเรียนรู้จากข้อมูลโดยการหาค่าที่ลดฟังก์ชันการสูญเสีย (Loss Function) ของแบบจำลองให้ได้มากที่สุด ซึ่งในกรณีของการจำแนกประเภทจะใช้ Log-Likelihood Function เป็นหลัก

2.1.7 การทำรีกูลารไรเซชัน (Regularization)

รีกูลารไรเซชัน (Regularization) เป็นเทคนิคที่ใช้เพื่อควบคุมไม่ให้แบบจำลองเกิดปัญหาการเรียนรู้มากเกินไป (Overfitting) โดยการเพิ่มค่าปรับโทษ (Penalty Term) เข้าไปในฟังก์ชันการสูญเสียของแบบจำลองทำให้สัมประสิทธิ์ของตัวแปรบางตัวไม่สามารถเติบโตมากเกินไปได้ ส่งผลให้แบบจำลองมีความซับซ้อนน้อยลงและสามารถตีความได้ง่ายขึ้น โดยการรีกูลารไรเซชันแบ่งออกได้เป็น 2 ประเภทหลัก ได้แก่

1. L1 Regularization หรือที่รู้จักในชื่อ Lasso
2. L2 Regularization หรือที่รู้จักในชื่อ Ridge

2.1.8 การจำแนกประเภทด้วย Regularization: Lasso Logistic Regression

การถดถอยโลจิสติกแบบลาสโซ (Lasso Logistic Regression) เป็นการนำแนวคิดของการถดถอยโลจิสติกมาผสมผสานกับ L1 Regularization โดยมีวัตถุประสงค์เพื่อเพิ่มประสิทธิภาพของแบบจำลองในการจำแนกประเภท และลดจำนวนตัวแปรที่ไม่จำเป็นออกจากแบบจำลอง

รูปแบบของฟังก์ชันการสูญเสียในกรณีของ Lasso Logistic Regression คือ

$$\text{Loss} = -\sum_{i=1}^{n} [y_i \log(p_i) + (1 - y_i) \log(1 - p_i)] + \lambda \sum_{j=1}^{p} |\beta_j|$$

ภาพประกอบที่ 2.3 Lasso Logistic Regression

โดยที่ λ เป็นพารามิเตอร์ควบคุมความเข้มของการลงโทษ (Penalty Strength) หาก λ มีค่ามาก แบบจำลองจะลงโทษสัมประสิทธิ์มากขึ้น ทำให้ค่าสัมประสิทธิ์บางตัวกลายเป็นศูนย์ ซึ่งเป็นผลดีต่อการลดจำนวนตัวแปรที่ไม่สำคัญ และเพิ่มความสามารถในการตีความผลลัพธ์ การใช้ Lasso Logistic Regression จึงเหมาะสมในกรณีที่ข้อมูลมีจำนวนตัวแปรจำนวนมาก หรือมีความเสี่ยงที่จะเกิด Overfitting โดยเฉพาะอย่างยิ่งในปัญหาที่ข้อมูลมีมิติมาก (High-dimensional Data)

2.1.9 การประเมินประสิทธิภาพแบบจำลองด้วย K-Fold Cross Validation

K-Fold Cross Validation คือ เทคนิคหนึ่งในการประเมินความแม่นยำของแบบจำลองทางสถิติหรือการเรียนรู้ของเครื่อง (Machine Learning) โดยเฉพาะอย่างยิ่งในกรณีที่มีข้อมูลจำกัด การประเมินด้วยวิธีนี้จะช่วยลดปัญหาแบบจำลองจำค่าข้อมูลเฉพาะ (Overfitting) และทำให้ผลลัพธ์ที่ได้มีความน่าเชื่อถือมากยิ่งขึ้น หลักการ คือ ทำงานโดยการแบ่งชุดข้อมูลทั้งหมดออกเป็น K ส่วนเท่า ๆ กัน (เรียกว่า “fold”) จากนั้นทำการฝึกสอนแบบจำลอง(Train) และทดสอบแบบจำลอง(Test) K ครั้ง โดยในแต่ละครั้งจะมี 1 fold ที่ใช้เป็นชุดทดสอบ และที่เหลืออีก K-1 folds จะใช้เป็นชุดฝึกสอน

2.1.10 การประเมินประสิทธิภาพของแบบจำลอง (Model Evaluation)

เมทริกซ์ความสับสน (Confusion Matrix) เมทริกซ์นี้แสดงผลการจำแนกประเภทโดยเปรียบเทียบค่าที่ทำนายกับค่าจริง แบ่งออกเป็น 4 กรณี:

- **True Positives (TP):** จำนวนตัวอย่างที่เป็นบวกและทำนายว่าเป็นบวกถูกต้อง
- **True Negatives (TN):** จำนวนตัวอย่างที่เป็นลบและทำนายว่าเป็นลบถูกต้อง
- **False Positives (FP):** จำนวนตัวอย่างที่เป็นลบแต่ทำนายผิดว่าเป็นบวก (Type I Error)
- **False Negatives (FN):** จำนวนตัวอย่างที่เป็นบวกแต่ทำนายผิดว่าเป็นลบ (Type II Error)

จากค่าเหล่านี้ สามารถคำนวณเมตริกที่สำคัญสำหรับการประเมินแบบจำลองบนข้อมูลที่ไม่สมดุลได้ ดังนี้:

- **Accuracy (ความแม่นยำ):** เป็นความแม่นยำสำหรับการจำแนกประเภท ซึ่งวัดจากจำนวนการทำนายประเภทข้อมูลตัวอย่างที่ถูกต้องหารด้วยจำานวนข้อมูลตัวอย่างทั้งหมด
- **Precision (ความเที่ยง):** เป็นสัดส่วนของตัวอย่างที่ทำนายว่าเป็นบวกซึ่งเป็นบวกจริง ๆ มีความสำคัญเมื่อต้องการลดจำนวนผลบวกลวง (False Positives) เช่น ในการระบุว่าความคิดเห็นที่ถูกทำนายว่าเป็นบวกนั้นเป็นบวกจริงหรือไม่
- **Recall (Sensitivity, ความระลึก):** เป็นสัดส่วนของตัวอย่างที่เป็นบวกทั้งหมดที่แบบจำลองสามารถตรวจจับได้ถูกต้อง มีความสำคัญอย่างยิ่งเมื่อต้องการหาตัวอย่างที่เป็นบวกให้ได้มากที่สุด (ลด False Negatives) เช่น การตรวจจับความคิดเห็นเชิงลบทั้งหมดที่มีอยู่
- **F1-Score:** คือค่าเฉลี่ยฮาร์มอนิก (harmonic mean) ของ Precision และ Recall F1-Score ให้ค่าเดียวที่สมดุลระหว่าง Precision และ Recall และมักนิยมใช้เป็นเมทริกซ์หลักสำหรับประเมินประสิทธิภาพบนข้อมูลที่ไม่สมดุล

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

$$F_1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall}$$

ภาพประกอบที่ 2.4: Confusion Matrix

ที่มา: An Introduction to Statistical Learning with Applications in R Textbook © 2021

2.2 งานวิจัยที่เกี่ยวข้อง

2.2.1 งานวิจัยการวิเคราะห์ความรู้สึก

ชวิต ภูมิพนา (2564) วิเคราะห์และจำแนกความรู้สึกของผู้บริโภคซึ่งแสดงความคิดเห็นเกี่ยวกับสถานที่ท่องเที่ยวและที่พักบน Facebook โดยประยุกต์ใช้แบบจำลอง Naïve Bayes พร้อมกระบวนการตัดคำภาษาไทยเพื่อเตรียมข้อมูลก่อนสกัดคุณลักษณะ ผลการทดลองปรากฏว่า ค่าประสิทธิภาพต่าง ๆ ได้แก่ Precision, Recall, Accuracy และ F-measure อยู่ในช่วง 98.4–98.5% ซึ่งชี้ให้เห็นอย่างชัดเจนว่าการตัดคำภาษาไทยมีอิทธิพลสำคัญต่อความแม่นยำของการวิเคราะห์ข้อความอย่างยิ่งมากขึ้นกว่าองค์ประกอบอื่น ๆ ของแบบจำลองแบบจำลอง

กสิทธิ์ สุรชาติ และคณะ (2567) นำเสนอแบบจำลองไฮบริดแบบคู่ขนานโดยบูรณาการ WangchanBERTa เข้ากับสถาปัตยกรรม CNN-BiLSTM และ BiLSTM-CNN เพื่อรับมือกับความหลากหลายของความยาวข้อความ ผลการทดลองบนชุดข้อมูล Wisesight และ Thai Children’s Tales ให้คะแนน Macro F1 สูงสุดที่ 0.6270 และ 0.7859 ตามลำดับ ซึ่งดีกว่าการใช้สถาปัตยกรรมเดียว พร้อมชี้ให้ศึกษาการจัดการกับความไม่สมดุลของประเภทและปรับไฮเปอร์พารามิเตอร์อย่างเป็นระบบ

Stefano Grassi (2025) ศึกษาการจำแนกความรู้สึกในประโยคจากข่าวประชาสัมพันธ์ของธนาคารแห่งประเทศไทยโดยใช้ ChatGPT ร่วมกับผู้เชี่ยวชาญในการติดป้าย sentiment พร้อมเตรียมข้อมูลด้วย custom tokenizer และ TfidfVectorizer ก่อนฝึก Naive Bayes, SVM และ Random Forest ปรับไฮเปอร์พารามิเตอร์ด้วย Grid Search (5-fold CV) พบว่า Naive Bayes ให้ Macro-F1 สูงสุดที่ 0.75 ต่อด้วย SVM (0.71) และ Random Forest (0.62) ซึ่งบ่งชี้ว่าแบบจำลองง่ายให้ผลสมดุลที่สุดในชุดข้อมูลจำกัด แนะนำให้พัฒนาหลักเกณฑ์และเครื่องมือสำหรับการติดป้ายข้อมูลเพื่อเพิ่มความแม่นยำ ลดอคติและ สร้างแบบจำลอง sentiment analysis สำหรับข้อความภาษาไทยโดยตรงต่อไป

Knavoot Jiamwattanapong et al. (2024) พัฒนาแบบจำลองการวิเคราะห์ความรู้สึกสำหรับรีวิวธนาคารไทย โดยใช้เทคนิคการเรียนรู้ลึก (Deep Learning) ร่วมกับ Robust Optimization เพื่อจัดการกับข้อมูลที่ไม่สมดุล (Imbalanced Data) แบบจำลองที่ใช้ประกอบด้วย CNN, RNN, LSTM, และ GRU โดยเพิ่มประสิทธิภาพการจำแนกความคิดเห็นและความทนทานต่อข้อมูลที่ไม่สมดุลด้วยเทคนิค SMOTE ผลลัพธ์ที่ได้แสดงว่า แบบจำลองที่ปรับแต่งมีความแม่นยำสูงขึ้นและสามารถจัดการกับข้อมูลที่ไม่สมดุลได้ดีขึ้น

2.2.2 การวิเคราะห์เนื้อหาที่สร้างโดยผู้ใช้จากโซเชียลมีเดีย

ธรา อั่งสกุล และคณะ (2567) ศึกษาการวิเคราะห์ความรู้สึกจากข้อความ ทวีตอีโมติคอน และภาพจาก Twitter เพื่อพยากรณ์ระดับภาวะซึมเศร้าเบื้องต้น ทำ Pre-processing แล้วใช้แบบจำลองMachine Learning หลายรูปแบบในการจำแนก sentiment ของผู้ใช้ ผลการศึกษาช่วยยืนยันว่าการนำหลักการ Sentiment Analysis มาประยุกต์ในบริบททางสุขภาพจิตสามารถช่วยคัดกรองผู้เสี่ยงได้ในระดับที่น่าพอใจ

Padhanarath et al. (2019) พัฒนาแบบจำลองNaive Bayes เพื่อวิเคราะห์ความรู้สึกจากความคิดเห็นใน Pantip.com และศึกษาความสัมพันธ์กับตลาดหุ้น SET พบว่า sentiment จากโซเชียลมีเดียสัมพันธ์กับราคาหุ้นบางส่วน (แม่นยำ 74%) โดยยังมีปัจจัยอื่น เช่น เศรษฐกิจและการเมืองร่วมด้วย ข้อเสนอแนะคือธุรกิจสามารถใช้การวิเคราะห์ความรู้สึกเพื่อเข้าใจลูกค้าและตลาดให้ดียิ่งขึ้น

2.2.3 การประยุกต์ใช้ TF-IDF และ Lasso Logistic Regression ที่เกี่ยวข้อง

พิเชษฎ์ จุลรอด และดินสอ บุญมา (2566) วิเคราะห์ความคิดเห็นของผู้บริโภคที่ใช้บริการร้านอาหารในมหาวิทยาลัยเชียงใหม่ โดยใช้ PyThaiNLP ในการตัดคำ และใช้แบบจำลอง Logistic Regression เพื่อจำแนกระดับความรู้สึกในข้อความ 3 ระดับ ได้แก่ ความคิดเห็นเชิงบวก เป็นกลาง และเชิงลบ ซึ่งผลลัพธ์แสดงให้เห็นว่าแบบจำลองสามารถจำแนกข้อความได้อย่างเหมาะสม และช่วยให้ร้านค้าเข้าใจความต้องการของผู้ใช้บริการได้ชัดเจนมากขึ้น

พิศิษฐ์ บวรเลิศสุธี และ วรภัทร ไพรีเกรง (2565) งานวิจัยนี้นำเสนอการสร้างตัวแบบสำหรับการวิเคราะห์ระดับความรู้สึกของการแสดงความคิดเห็นต่อสินค้าและบริการออนไลน์ โดยใช้เทคนิคการเรียนรู้ของเครื่อง (Machine Learning) เช่น K-Nearest Neighbors, Random Forest, Logistic Regression และ Support Vector Machines (SVM) ร่วมกับการตัดคำและการสร้างคลังคำศัพท์ (Bag of Words) เพื่อจำแนกความคิดเห็นเป็นเชิงบวก เป็นกลาง และเชิงลบ

Olamilekan Shobayo (2024) เปรียบเทียบ FinBERT, GPT-4 และ Logistic Regression ในการวิเคราะห์ความรู้สึกจากข่าวการเงินและทำนายดัชนีหุ้น NGX พบว่า Logistic Regression มีประสิทธิภาพสูงสุด (Accuracy 81.83%, ROC AUC 89.76%) ส่วน GPT-4 แม้แม่นยำน้อยกว่า แต่จัดการข้อมูลซับซ้อนได้ดี งานวิจัยแนะนำให้ใช้ Logistic Regression ในงานที่ต้องการความแม่นยำและประหยัดทรัพยากร พร้อมปรับแต่งแบบจำลองเพื่อเพิ่มประสิทธิภาพ

ตารางสรุปงานวิจัยที่เกี่ยวข้องที่สำคัญ

งานวิจัย	วัตถุประสงค์	ชุดข้อมูล	ระเบียบวิธี/เทคนิค	ผลการวิจัย	ข้อจำกัด
พิเชษฎ์ จุลรอด และดินสอ บุญมา (2566)	วิเคราะห์ sentiment รีวิวร้านอาหาร มช. (บวก/เป็นกลาง/ลบ)	รีวิวลูกค้าร้านอาหาร มหาวิทยาลัยเชียงใหม่	PyThaiNLP ตัดคำ + Logistic Regression (3 ระดับ sentiment)	โมเดลจำแนกข้อความได้เหมาะสม ช่วยให้ร้านค้าเข้าใจความต้องการชัดขึ้น	ข้อมูลเฉพาะร้าน มช. ขนาด dataset ไม่ชัดเจน ต้องระบุเพิ่มเติม
พิศิษฐ์ บวรเลิศสุธี และ วรภัทร ไพรีเกรง (2565	พัฒนาตัวแบบ sentiment รีวิวสินค้า/บริการออนไลน์	รีวิวสินค้าและบริการออนไลน์	K-Nearest Neighbors, Random Forest, Logistic Regression, SVM + Bag-of-Words	สามารถจำแนก sentiment 3 ระดับได้ (บวก/กลาง/ลบ)	ต้องปรับ vocab เฉพาะด้าน
ธรา อั่งสกุล และคณะ (2567)	วิเคราะห์ Sentiment จากทวีต เพื่อทำนายระดับภาวะซึมเศร้า	Twitter (ข้อความ, อีโมติคอน, รูปภาพ)	Hybrid ML (SVM Feature Selection, Random Forest)	แบบจำลองที่พัฒนาขึ้นมีประสิทธิภาพสูงสุด	แนะนำให้ปรับจูน hyperparameter อย่างละเอียด
ชวิต ภูมิพนา (2564)	วิเคราะห์และจำแนกความรู้สึกของผู้บริโภคเกี่ยวกับสถานที่ท่องเที่ยวและที่พักบน Facebook	ความคิดเห็นเกี่ยวกับสถานที่ท่องเที่ยวและที่พักบน Facebook	Naïve Bayes, การตัดคำภาษาไทย	อยู่ในช่วง 98.4–98.5%. การตัดคำมีอิทธิพลสำคัญต่อความแม่นยำอย่างยิ่ง	เน้นย้ำความสำคัญของการตัดคำ
กสิทธิ์ สุรชาติ และคณะ (2567)	นำเสนอโมเดลไฮบริดเพื่อรับมือกับความหลากหลายของความยาวข้อความในการวิเคราะห์ความรู้สึก	Wisesight, Thai Children’s Tales	โมเดลไฮบริดแบบคู่ขนาน (WangchanBERTa + CNN-BiLSTM, WangchanBERTa + BiLSTM-CNN)	Macro F1 สูงสุด 0.6270 (Wisesight) และ 0.7859 (Thai Children's Tales), ดีกว่าสถาปัตยกรรมเดียว	ศึกษาการจัดการกับความไม่สมดุลของประเภทและปรับไฮเปอร์พารามิเตอร์อย่างเป็นระบบ
Stefano Grassi (2025	จำแนกความรู้สึกในประโยคจากข่าวประชาสัมพันธ์ของธนาคารแห่งประเทศไทย	ข่าวประชาสัมพันธ์ของธนาคารแห่งประเทศไทย (ติดป้ายโดย ChatGPT + ผู้เชี่ยวชาญ)	ChatGPT (ติดป้าย), custom tokenizer, TfidfVectorizer, Naive Bayes, SVM, Random Forest, Grid Search (5-fold CV)	Naive Bayes ให้ Macro-F1 สูงสุด (0.75), ตามด้วย SVM (0.71), Random Forest (0.62). โมเดลง่ายให้ผลดีในชุดข้อมูลจำกัด	พัฒนาหลักเกณฑ์และเครื่องมือติดป้ายข้อมูลเพื่อเพิ่มความแม่นยำ ลดอคติ และสร้างโมเดล sentiment สำหรับภาษาไทยโดยตรง
Sasipa, S., Nittiya, T., & Thanaruk, T. (2024)	พัฒนาโมเดลวิเคราะห์ความรู้สึกรีวิวธนาคารไทย จัดการข้อมูลที่ไม่สมดุล	รีวิวธนาคารไทย	Deep Learning (CNN, RNN, LSTM, GRU), Robust Optimization, SMOTE	โมเดลที่ปรับแต่งมีความแม่นยำสูงขึ้นและจัดการข้อมูลที่ไม่สมดุลได้ดีขึ้น	-

Padhanarath et al. (2019)	วิเคราะห์ความรู้สึกจาก Pantip.com และศึกษาความสัมพันธ์กับตลาดหุ้น SET	ความคิดเห็นจาก Pantip.com, ข้อมูลตลาดหุ้น SET	Naive Bayes	Sentiment สัมพันธ์กับราคาหุ้นบางส่วน (แม่นยำ 74%), มีปัจจัยอื่นร่วมด้วย	ธุรกิจสามารถใช้การวิเคราะห์ความรู้สึกเพื่อเข้าใจลูกค้าและตลาด
Olamilekan Shobayo (2024)	เปรียบเทียบ FinBERT, GPT-4, Logistic Regression ในการวิเคราะห์ความรู้สึกข่าวการเงินและทำนายดัชนีหุ้น NGX	ข่าวการเงิน, ดัชนีหุ้น NGX	FinBERT, GPT-4, Logistic Regression	Logistic Regression มีประสิทธิภาพสูงสุด (Accuracy 81.83%, ROC AUC 89.76%). GPT-4 จัดการข้อมูลซับซ้อนได้ดี แต่แม่นยำน้อยกว่า	ใช้ Logistic Regression ในงานที่ต้องการความแม่นยำและประหยัดทรัพยากร, ปรับแต่งโมเดลเพิ่มประสิทธิภาพ

ตารางที่ 2.1 สรุปงานวิจัยที่เกี่ยวข้องที่สำคัญ

จากการทบทวนวรรณกรรม พบว่ามีโอกาสให้โครงงานนี้เข้าไปเติมเต็ม ดังนี้

2.3.1 ความเฉพาะเจาะจงของโดเมน (Domain Specificity)

งานวิจัยส่วนใหญ่เน้นการวิเคราะห์ความรู้สึก เช่น รีวิวร้านอาหารในมหาวิทยาลัยเชียงใหม่ หรือความคิดเห็นบนโซเชียลมีเดีย อย่างไรก็ตามยังไม่มีงานที่มุ่งวิเคราะห์ความคิดเห็นเกี่ยวกับ “โบรกเกอร์หุ้นไทย” โดยตรง ทั้งคำศัพท์ รูปแบบประโยค และวิธีสื่อสารของลูกค้าโบรกเกอร์ จึงต้องออกแบบแบบจำลองให้เหมาะกับบริบทนี้โดยเฉพาะ

2.3.2 ความเฉพาะเจาะจงของแพลตฟอร์ม (Platform Specificity)

แพลตฟอร์มพันทิปมีโครงสร้าง multi-turn, สแลง และการสลับภาษา แต่งาน sentiment analysis ทางการเงินบนพันทิปยังน้อยและมักใช้เทคนิคทั่วไป จึงจำเป็นต้องสร้างระบบวิเคราะห์แบบใหม่ที่เข้าใจลักษณะเฉพาะของพันทิปเพื่อให้ผลลัพธ์แม่นยำขึ้น

2.3.3 การผสมผสานระเบียบวิธีวิจัย (Methodological Combination)

แม้ TF-IDF กับ Lasso Logistic Regression จะเป็น ขั้นตอนที่มักถูกนำมาใช้ร่วมกัน แต่ยังไม่มีงานประเมินประสิทธิภาพของการรวมสองเทคนิคนี้ในงาน sentiment

2.3.4 การจัดการข้อมูลไม่สมดุล (Imbalance Handling in Context)

ความเห็นต่อโบรกเกอร์อาจมีสัดส่วน positive/neutral/negative ไม่เท่ากัน จึงต้องทดลองเทคนิคจัดการ class imbalance เช่น Under Sampling เพื่อหาวิธีที่ให้ผลลัพธ์ดีที่สุดบนชุดข้อมูลพันทิป

บทที่ 3
การดำเนินงานวิจัย

ในงานวิจัยครั้งนี้ ผู้วิจัยได้ดำเนินการตามขั้นตอน ดังนี้

3.1 การออกแบบกระบวนการและวิธีการดำเนินงานวิจัย

3.2 การเก็บรวบรวมข้อมูล

3.3 การเตรียมความพร้อมของข้อมูล (Data Preparation)

3.4 การแบ่งกลุ่มข้อมูล (Category Classification)

3.5 การวิเคราะห์ความรู้สึก (Sentiment Analysis)

3.6 การประเมินผลแบบจำลอง

3.1 การออกแบบกระบวนการและวิธีการดำเนินการวิจัย

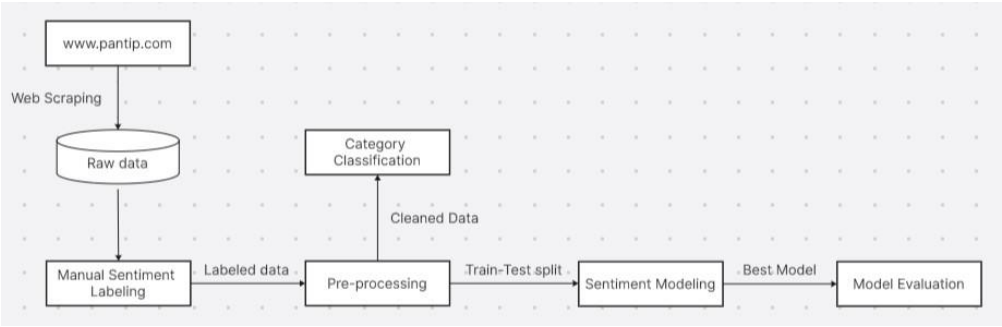

ภาพประกอบที่ 3.1 แสดงกระบวนการดำเนินงานวิจัย

3.2 การเก็บรวบรวมข้อมูล

ในงานวิจัยนี้ทำการเก็บรวบรวมข้อมูลที่เป็นข้อความความคิดเห็นจาก www.pantip.com โดยใช้วิธีการ Web Scraping โดยใช้ภาษา ไพธอน และ ไลบรารี่ Selenium มี 3 ขั้นตอนดังนี้ ขั้นตอนที่ 1 ทำการค้นหา website ที่ต้องการ โดยคัดเลือก website ที่มีแท็กเป็น ‘โบรกเกอร์’, ‘broker’ ขั้นตอนที่ 2 วิเคราะห์โครงสร้าง HTML ด้วยเครื่องมือ Inspect Element เพื่อระบุ Class Name ของข้อมูลที่ต้องการ (ชื่อกระทู้, เนื้อหา, ความคิดเห็น) จากนั้นใช้ Selenium สั่งให้เบราว์เซอร์ดึงข้อความเหล่านั้นออกมา โดยมีการจัดการกับการเปลี่ยนหน้า (Pagination) เพื่อให้ได้ข้อมูลครบถ้วน และในขั้นตอนที่ 3 เมื่อได้รับข้อมูลแล้วจะทำการบันทึกข้อมูลในรูปแบบ CSV File เพื่อนำข้อมูลที่ได้ไปเตรียมความพร้อมของข้อมูลต่อไป

ภาพประกอบที่ 3.2 แสดงขั้นตอนการดึงข้อมูลจากเว็บไซต์

ภาพประกอบที่ 3.3 แสดงตัวอย่างหน้าจอเว็บไซต์ *www.pantip.com*

3.2.2 ชุดข้อมูล (Dataset)

ผู้วิจัยได้ทำการดึงข้อมูล ณ วันที่ 4 มีนาคม 2568 มีจำนวนข้อความทั้งหมด 1327 ข้อความ โดยข้อมูลจะประกอบไปด้วย 4 คอลัมน์ คือ ลิงก์กระทู้ (topic_url), หัวข้อกระทู้ (thread_title), หมายเลขสมาชิก (author), รายละเอียดคอมเมนต์ (comment) รายละเอียดตามภาพประกอบที่ 3.4

topic_url	thread_title	author	comment
https://pantip.com/topic/43014994	แนะนำโบรกเกอร์เทรดหุ้นออนริกาที่ไม่เสียค่าคอมดีขั้นพร้อมบัญชีธนาคารด้วย	สมาชิกหมายเลข 3665628	ก่อนอื่นขอบอกก่อนว่าผมไม่ได้ดำโฆษณา แต่เป็นลูกค้าจริง Charles Schwab ตามลิงค์ข้างล่างครับ เอกสารแอกสารในการเปิดบัญชี 1. หนังสือเดินทางที่ยังไม่หมดอายุ
https://pantip.com/topic/43037681	มีโบรกเกอร์ไหนสามารถซื้อหุ้	สมาชิกหมายเลข 1422153	มีโบรกเกอร์ไหนในไทยสามารถซื้อหุ้นจากตลาด otc ได้บ้างครับ
https://pantip.com/topic/42589290	โบรกเกอร์หุ้นคะ	สมาชิกหมายเลข 8036706	ทุกคนคิดว่าโบรคไหนดีคะ ทางนี้กำลังตัดสินใจโบรกxm ///เราเทรดในแอพMt5นะคะ ใครเคยเทรดหุ้นใช้โบรกอะไรยิ่งเทรดในmt5เหมือนกันยิ่งดีเลยค่ะ ขออามจากผู้มีประสบการณ์ค่ะ
https://pantip.com/topic/42589290	โบรกเกอร์หุ้นคะ	จะไหวเหรอ	เอ๊กเอ็ม มันโบรกฟ่อเร็กนิครับ มันไม่น่าจะใช้โบรกเทรดหุ้นครับ ถ้าเทร
https://pantip.com/topic/43059564	ขอคำแนะนำออนไลน์โบรกเก	parn 256	อุก มีทั้งหุ้นในประเทศ 0.06 และ หุ้น us 0.10 มั้งถ้าจำไม่ผิด ลองดูที่ liberator
https://pantip.com/topic/42974250	เปิดพอร์ตหุ้นเลือกโบรกเกอร์	สมาชิกหมายเลข 7125441	รีวิวจากคนใช้งานจริง 1. InnovestX บัญชีเงินสด Cash Balance ฝากขั้นต่ำ 100 บาท ถอนขั้นต่ำ 2,000 บาท ค่าคอมเวลาซื้อ 0.157% ข้อดีเป็นโบรกเกอร์ที่อยู่ภายใต้ธนาคาร ติดต่อง่ายเวลามีปัญหาไป ถามพนักงานที่สาขาธนาคารใกล้บ้านได้ ใช้ฟังก์ชั่น Conditional Order ไม่ได้ 2. K secruties บัญชีเงินสด Cash Balance ถอนขั้นต่ำ 5,000 บาท ค่าคอมเวลาซื้อบาท 0.157% ใช้ฟังก์ชั่น Conditional Order ได้ 3. Librerator ค่าคอมถูก 0.007% 4. Dime ข้อดีลงทุนได้หลายอย่าง กองทุนรวมไทยและต่างประเทศ หุ้นไทย หุ้นเมกา ทองคำ หุ้นเมกาซื้อขั้นต่ำ 50 บาท หุ้นไทยต้องซื้ออย่างน้อย 100 หุ้น รายละเอียดดูได้ที่วิดีโอนี้เลยครับ
https://pantip.com/topic/43253613	สอบถามเรื่องโอนย้ายหุ้น Cas	สมาชิกหมายเลข 2933266	ย้ายไป sbito ถึงราคาหุ้นจะถัวเฉลี่ยกัน แต่เวลาขายมันจะแบ่งราคา ก
https://pantip.com/topic/42598957	โบรกเกอร์ไหนซื้อหุ้นฮ่องกงแ	สมาชิกหมายเลข 1422153	โบรกเกอร์ไหนซื้อหุ้นฮ่องกงแบบเศษหุ้นได้บ้าง ซื้อยากมาก หุ้นอเม
https://pantip.com/topic/42741815	หากเราลงทนหุ้นต่างประเทศ	สมาชิกหมายเลข 8186644	ในกรณีที่โบรกเกอร์ปิดตัวลง เราสามารถติดตามหุ้นของเราได้ยังไงบ้า

ภาพประกอบที่ 3.4 แสดงตัวอย่างชุดข้อมูล

3.3 การเตรียมความพร้อมของข้อมูล (Data Preparation)

3.3.1 อ่านข้อความและระบุ Label (Manual Labeling)

ผู้วิจัยได้ทำการเพิ่มคอลัมน์ “sentiment” เพื่อระบุความรู้สึกของข้อความ (Labeled data) จำนวน 1327 ข้อความ โดยมีจำนวนของข้อมูลแต่ละความรู้สึก ตัวอย่างชุดข้อมูลตามภาพประกอบ 3.5 และ 3.6

ลำดับ	ความรู้สึก	จำนวน
1	บวก	479
2	กลาง	545
3	ลบ	303

ภาพประกอบที่ 3.5 แสดงจำนวนข้อมูลของแต่ละความรู้สึก

topic_url	thread_title	author	comment	sentimer
https://pantip.com/topic/43014994	แนะนำโบรกเกอร์เทรดหุ้นอเมริกาที่ไม่เสียค่าคอมมิชชั่น พร้อมบัญชีธนาคารด้วย	สมาชิกหมายเลข 3665628	ก่อนอื่นขอบอกก่อนว่าผมไม่ได้ค่าโฆษณา แต่เป็นลูกค้าจริง Charles Schwab ตามลิงค์ข้างล่างครับ เอกสารเอกสารในการเปิดบัญชี 1. หนังสือเดินทางที่ยังไม่หมดอายุ	บวก
https://pantip.com/topic/43037681	มีโบรกเกอร์ไหนสามารถซื้อหุ้	สมาชิกหมายเลข 1422153	มีโบรกเกอร์ไหนในไทยสามารถซื้อหุ้นจากตลาด otc ได้บ้างครับ	กลาง
https://pantip.com/topic/42589290	โบรกเกอร์หุ้นค่ะ	สมาชิกหมายเลข 8036706	ทุกคนคิดว่าโบรคไหนดีคะ ทางนี้กำลังตัดสินใจโบรกxm ///เราเทรดในแอพMt5นะคะ ใครเคยเทรดหุ้นใช้โบรกอะไรยิ่งเทรดในmt5เหมือนกันยิ่งดีเลยค่ะ ขอถามจากผู้มีประสบการณ์ค่ะ	กลาง
https://pantip.com/topic/42589290	โบรกเกอร์หุ้นค่ะ	จะไหวเหรอ	เอ็กเอ็ม มันโบรกฟอเร็กนิครับ มันไม่น่าจะใช่โบรกเทรดหุ้นครับ ถ้าเทร	กลาง
https://pantip.com/topic/43059564	ขอคำแนะนำออนไลน์โบรกเก	parn 256	ถูก มีทั้งหุ้นในประเทศ 0.06 และ หุ้น us 0.10 มั้งถ้าจำไม่ผิด ลองดูที่ liberator	กลาง
https://pantip.com/topic/42974250	เปิดพอร์ตหุ้นเลือกโบรกเกอร์ไ	สมาชิกหมายเลข 7125441	รีวิวจากคนใช้งานจริง 1. InnovestX บัญชีเงินสด Cash Balance ฝากขั้นต่ำ 100 บาท ถอนขั้นต่ำ 2,000 บาท ค่าคอมเวลาซื้อ 0.157% ข้อดีเป็นโบรกเกอร์ที่อยู่ภายใต้ธนาคาร ติดต่อง่ายเวลามีปัญหาไปถามพนักงานที่สาขาธนาคารใกล้บ้านได้ ใช้ฟังก์ชั่น Conditional Order ไม่ได้ 2. K secruities บัญชีเงินสด Cash Balance ถอนขั้นต่ำ 5,000 บาท ค่าคอมเวลาซื้อบาท 0.157% ใช้ฟังก์ชั่น Conditional Order ได้ 3. Librerator ค่าคอมถูก 0.007% 4. Dime ข้อดีลงทุนได้หลายอย่าง กองทุนรวมไทยและต่างประเทศ หุ้นไทย หุ้นเมกา ทองคำ หุ้นเมกาซื้อขั้นต่ำ 50 บาท หุ้นไทยต้องซื้ออย่างน้อย 100 หุ้น รายละเอียดดูได้ที่วิดีโอนี้เลยครับ	บวก
https://pantip.com/topic/43253613	สอบถามเรื่องโอนย้ายหุ้น Cas	สมาชิกหมายเลข 2933266	ย้ายไป sbito ถึงราคาหุ้นจะถัวเฉลี่ยกัน แต่เวลาขายมันจะแบ่งราคา กร	บวก
https://pantip.com/topic/42598957	โบรกเกอร์ไหนซื้อหุ้นฮ่องกงแ	สมาชิกหมายเลข 1422153	โบรกเกอร์ไหนซื้อหุ้นฮ่องกงแบบเศษหุ้นได้บ้าง ซื้อยากมาก หุ้นอเม	กลาง
https://pantip.com/topic/42741815	หากเราลงทุนหุ้นต่างประเทศ	สมาชิกหมายเลข 8186644	ในกรณีที่โบรกเกอร์ปิดตัวลง เราสามารถติดตามหุ้นของเราได้ยังไงบ้าง	กลาง

ภาพประกอบที่ 3.6 แสดงตัวอย่างชุดข้อมูลหลังระบุ Label

3.3.2 การทำความสะอาดข้อมูล ผู้วิจัยจะเริ่มต้นด้วยการจัดการค่าที่สูญหาย จากนั้นดำเนินการทำความสะอาดข้อความ โดยการแปลงสัญลักษณ์ Emoji ให้อยู่ในรูปของข้อความ ลบเครื่องหมายวรรคตอนที่ไม่จำเป็น ลบ URL และลบการกล่าวถึงบัญชีผู้ใช้อื่น (Mentions) หลังจากนั้น ข้อความจะถูกประมวลผลเพื่อลบคำหยุด (Stopwords) ของภาษาไทย และดำเนินการตัดแบ่งคำ (Word Tokenization) โดยใช้ไลบรารี PyThaiNLP ด้วยกลไก 'newmm' ทำให้ได้ชุดข้อมูลข้อความที่พร้อมสำหรับการวิเคราะห์ในขั้นตอนต่อไป ภาพที่ 3.7 แสดงการทำความสะอาดข้อความ

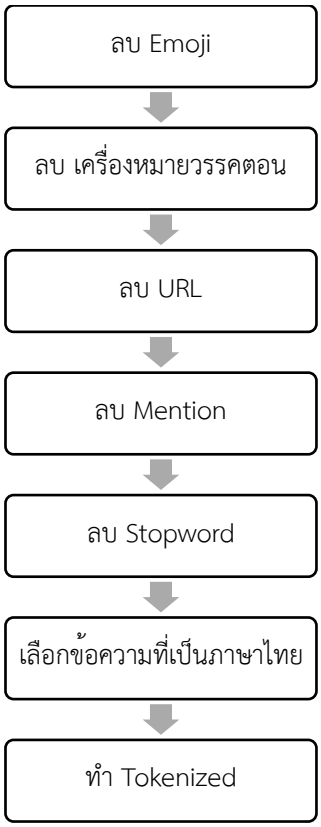

ภาพประกอบที่ 3.7 แสดงขั้นตอนการทำความสะอาดข้อความ

3.3.3 การสร้างกลุ่มคำ (Word Cloud) ในงานวิจัยนี้จะใช้ Word Cloud เพื่อแสดงความถี่ของคำที่ปรากฏอยู่ในแต่ละความรู้สึกของข้อความ หากคำใดที่ปรากฏบ่อยจะมีขนาดใหญ่ ดังภาพประกอบที่ 3.8 ถึงภาพประกอบที่ 3.10

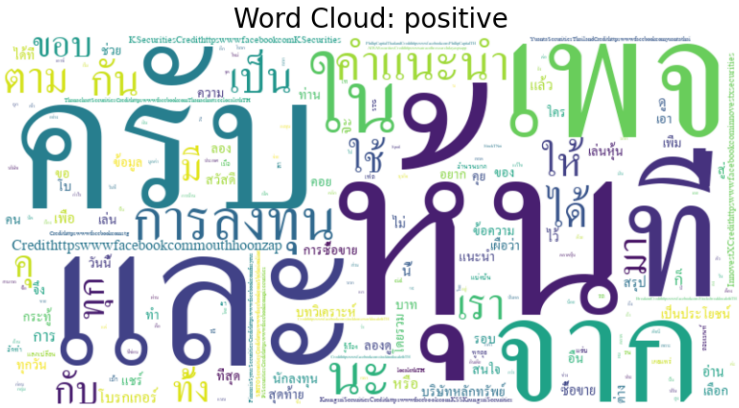

ภาพประกอบที่ 3.8 แสดงตัวอย่างการสร้างกลุ่มคำที่ปรากฏอยู่ในความรู้สึกของข้อความเป็น บวก

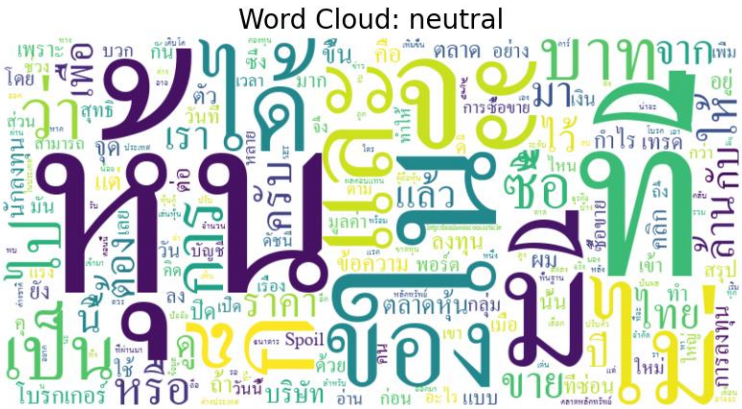

ภาพประกอบที่ 3.9 แสดงตัวอย่างการสร้างกลุ่มคำที่ปรากฏอยู่ในความรู้สึกของข้อความเป็น กลาง

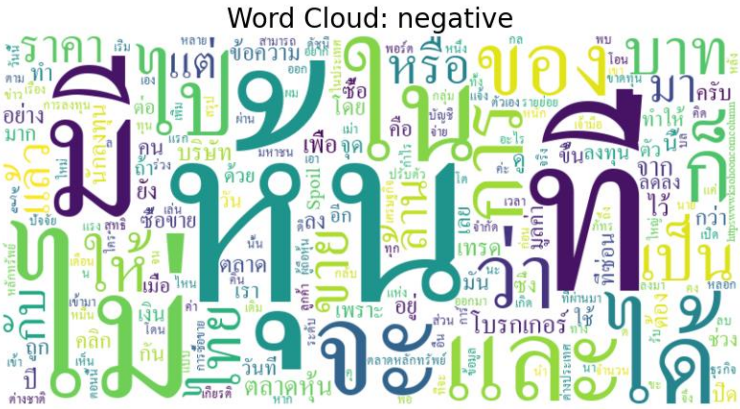

ภาพประกอบที่ 3.10 แสดงตัวอย่างการสร้างกลุ่มคำที่ปรากฏอยู่ในความรู้สึกของข้อความเป็น ลบ

3.4 การแบ่งกลุ่มข้อมูล (Category Classification)

ในขั้นตอนนี้ ผู้วิจัยนำรากศัพท์ (root words) จากขั้นตอนทำความสะอาดข้อมูล มารวบรวมเป็นชุดคำหลัก (keywords) สำหรับการแบ่งกลุ่มข้อความ ให้สอดคล้องกับหัวข้อหลัก ได้แก่ ปัญหาทางระบบ, ค่าธรรมเนียม, การบริการ, การเทรด, และอื่น ๆ ชุดคำหลักที่ได้จะถูกทดสอบกับข้อความต้นฉบับและปรับปรุงโดยการตรวจสอบความถูกต้องเบื้องต้น เพื่อให้การจำแนกหมวดหมู่มีความแม่นยำสูงสุด

หัวข้อ	Keywords
ปัญหาทางระบบ	ระบบล่ม, ช้า, error, บัค, ปัญหา, เชื่อมต่อ
ค่าธรรมเนียม	ค่าสมัคร, ค่าธรรมเนียม, คอมมิชชั่น, สเปรด, spread
การบริการ	บริการ, ลูกค้าสัมพันธ์, ซัพพอร์ต, ช่วยเหลือ, แพลตฟอร์ม, แอป, สอบถาม, แจ้ง, ข้อมูล , มือถือ, ฝาก, ถอน
การเทรด	เทรด, ซื้อขาย, หุ้น, order, execution, เลเวอเรจ, trade, brokerage, ราคา, พอร์ต, ปริมาณ, สัญญาณ, ตลท, ตลาดหลักทรัพย์, forex, โอนหลักทรัพย์
อื่นๆ	-

ตารางที่ 3.1 ตัวอย่างชุดคำหลักสำหรับการแบ่งกลุ่มข้อความ

3.5 การวิเคราะห์ความรู้สึก (Sentiment Analysis)

3.5.1 การจัดการข้อมูลไม่สมดุล (Data Balancing) เพื่อแก้ปัญหาจำนวนข้อความในแต่ละประเภทความรู้สึก ที่ไม่เท่ากันจาก 1327 ข้อความ (บวก 479, กลาง 545, ลบ 303) ผู้วิจัยจึงทำการ under sampling คือ สุ่มดึงข้อความแต่ละประเภทให้เท่ากับขนาดของประเภทที่มีจำนวนน้อยที่สุด (303 ข้อความ)

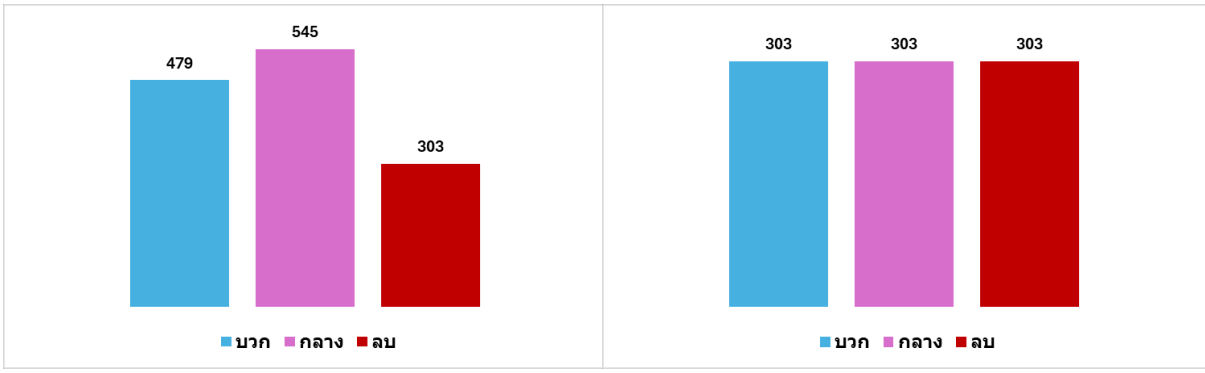

ภาพประกอบที่ 3.11 แสดงจำนวนข้อมูลหลังจากการทำ under sampling

3.5.2 การคัดแยกคำตามความสำคัญ (TF-IDF) ในงานวิจัยนี้ ผู้วิจัยได้ใช้ TF-IDF (Term Frequency–Inverse Document Frequency) มาใช้เป็นวิธีการคัดแยกและถ่วงน้ำหนักคำในชุดข้อความเพื่อสร้างคุณสมบัติ (feature) ให้กับแบบจำลอง Lasso Logistic Regression ที่กำหนดขนาดคลังคำศัพท์ (vocabulary) ไว้ไม่เกิน 5,000 คำ พร้อมกำหนดช่วงไวยากรณ์ (ngram_range) ตั้งแต่ 1-gram จนถึง 3-gram เพื่อให้สามารถรองรับทั้งคำเดี่ยวและวลีสั้นที่ พบบ่อยร่วมกัน กระบวนการคำนวณเริ่มจากการนับความถี่ของคำ (TF) ในแต่ละข้อความ จากนั้นนำมาถ่วงน้ำหนักด้วยค่า IDF ที่คำนวณจากจำนวนข้อความทั้งหมด ผลลัพธ์คือเมทริกซ์ TF-IDF ขนาด (จำนวนข้อความ × 5,000) ซึ่งแต่ละเซลล์จะแสดงค่าน้ำหนักของคำแต่ละคำในแต่ละข้อความดังภาพประกอบที่ 3.12

	ขึ้น	ขึ้นราคา	จาก	ตลาดหลักทรัพย์	ต่างชาติ	บาท	ปรับ	\
0	0.030809	0.483958	0.140016	0.041705	0.041344	0.477419	0.333637	
1	0.000000	0.000000	0.233553	0.000000	0.000000	0.000000	0.000000	
2	0.000000	0.000000	0.000000	0.000000	0.000000	0.051728	0.000000	
3	0.000000	0.000000	0.232652	0.000000	0.000000	0.000000	0.000000	
4	0.000000	0.000000	0.058431	0.000000	0.000000	0.000000	0.000000	

	ราคา	ลง	ลดราคา	หุ้น	หุ้น	เป็น	เป้าหมาย	\
0	0.028419	0.031758	0.070265	0.144541	0.066448	0.175142	0.553567	
1	0.000000	0.000000	0.000000	0.187523	0.000000	0.068167	0.000000	
2	0.052346	0.000000	0.000000	0.088746	0.000000	0.032260	0.000000	
3	0.000000	0.000000	0.000000	0.186800	0.000000	0.067904	0.000000	
4	0.000000	0.000000	0.000000	0.211118	0.000000	0.051163	0.000000	

	โบรกเกอร์	ให้ราคา	ไทย
0	0.023857	0.173408	0.052233
1	0.092854	0.000000	0.000000
2	0.021972	0.000000	0.000000
3	0.092496	0.000000	0.000000
4	0.000000	0.000000	0.000000

ภาพประกอบที่ 3.12 แสดงขั้นตอน และตัวอย่างคุณสมบัติจากการคำนวณ TF-IDF

3.5.2 การเตรียมตัวแปรต้นและตัวแปรตาม (Feature & Label Preparation) ผู้วิจัยได้ทำการกำหนดตัวแปรต้น X จากเมทริกซ์ TF-IDF และตัวแปรตาม y จาก sentiment ที่ทำการแปลงเป็นข้อมูลตัวเลขเรียบร้อยแล้ว และ ทำการแบ่งชุดข้อมูลออกเป็น ชุดข้อมูลฝึกฝนและชุดข้อมูลทดสอบที่อัตราส่วน 80:20 จึงได้จำนวนของข้อมูลแต่ละชุดข้อมูลเป็น ชุดฝึกฝน 727 ข้อความ และ ชุดทดสอบ 182 ข้อความ

```
203    หาก เพื่อน นักลงทุน สนใจ ลงทุน หุ้น กลุ่ม ปันผ...
143    สวัสดี ครับ เรา เป็น คน ที่ คอย ตาม อ่าน บทวิเ...
418    กฎ นะ มี ครับ แต่ ไม่ มี การควบคุมดูแล จน มาร์...
274    efinanceThaiTV ชั่วโมง ลงทุน หุ้น นอก ผ่าน ตลา...
231    คำแนะนำ หุ้น จาก เพจ การลงทุน เพจ เม้า หุ้น แช...
                                   ...
307    บล เกียรติ นา คิน ภัทร โบรกเกอร์ ROBOT สุนันท์...
661    ยัง หาไม่ เจอ เรื่อง ปันผล ถาม เอา จาก โบรก ก็...
142    คำแนะนำ หุ้น จาก เพจ การลงทุน เพจ เม้า หุ้น แช...
179    จาก หุ้น ที่ ผม ถือ อยู่ ใน มือ เหลืออยู่ ตอนน...
819    เดอะ วัน เอ็นเตอร์ไพรส์ ประกาศ เปลี่ยนแปลง สัด...
Name: comment_clean, Length: 727, dtype: object
```

```
718    GossipStationby เจ๊ จิ๋ม เรื่องราว ใน โลก ตก ก...
681    การ ใช้ มาร์จิ้น ใน การ ซื้อ หุ้น เพิ่ม ความเส...
579    แก๊งค์ callcenter เผลอไป คล้อยตาม มัน เงิน เกล...
761    โดย Zyohttpswwwfacebookcomzyobooks ประโยค ไม่ ...
802    หุ้น ที่อยู่ ใน พอร์ต มัน ไม่ มี วัน หาย หรอก ...
                                   ...
343    การ บิน ไทย แปลง หนี้ เป็น ทุน รวม ไม่ เกิน หม...
775    ผู้ถือหุ้น เตรียม จ่าย เงิน MGI ประกาศ เพิ่ม ท...
689    การ เทรด หุ้น ควรจะ ใช้ โบรกเกอร์ ที่ มี คะ กร...
592    GlobalTaxBy แม่มด น้อย วันที่ มกราคม พบ กับ แม...
498    พวก crypto นี่ แทบ ทั้งนั้น ตราบใดที่ คุ ไม โอ...
Name: comment_clean, Length: 182, dtype: object
```

ภาพประกอบที่ 3.13 แสดงข้อมูลหลังจากทำการแบ่งชุดข้อมูล

3.5.3 การฝึกแบบจำลองด้วย Lasso Logistic Regression และการค้นหาพารามิเตอร์ (Model Training & Hyperparameter Tuning) ในงานวิจัยนี้ใช้แบบจำลองที่ชื่อว่า Lasso Logistic Regression ที่ใช้ L1 Regularization ซึ่งเป็นการเพิ่มพจน์บทลงโทษ (penalty term) เพื่อปรับลดค่าสัมประสิทธิ์ (ค่าน้ำหนัก) ของแต่ละคุณลักษณะ (คำจาก TF-IDF) ที่ไม่สำคัญลงจนมีค่าเป็นศูนย์จริง (exact zeros) ซึ่งจะช่วยเลือกคำสำคัญที่มีน้ำหนัก TF-IDF สูงออกมาเป็นคุณสมบัติเด่น โดยการลบคำศัพท์ที่ไม่สำคัญทิ้ง (ทำให้ค่าน้ำหนักเป็น 0) ซึ่งช่วยให้แบบจำลองเน้นไปที่คำที่มีผลต่อความรู้สึกและ นำแบบจำลองมาฝึกฝนกับชุดข้อมูลฝึกฝน และใช้ในการทำนายข้อมูลกับชุดทดสอบ เพื่อทำการหาแบบจำลองที่มีประสิทธิภาพสูงที่สุดจากทั้งหมด

3.5.4 การประเมินประสิทธิภาพด้วย Stratified K-Fold Cross-Validation (10 folds) ในการประเมินประสิทธิภาพของแบบจำลอง ผู้วิจัยเลือกใช้เทคนิค Stratified K-Fold Cross-Validation โดยกำหนดให้จำนวนกลุ่ม (folds) เท่ากับ 10 เพื่อให้แบบจำลองได้เรียนรู้และทดสอบกับข้อมูลในสัดส่วนของคลาส Sentiment (บวก, กลาง, ลบ) ให้ใกล้เคียงกับข้อมูลทั้งหมด วิธีนี้ช่วยให้แบบจำลองได้เรียนรู้และทดสอบกับข้อมูลที่มีความหลากหลายอย่างเป็นระบบและลดปัญหาความไม่สมดุลของข้อมูล โดยในแต่ละรอบของการประเมิน โมเดลจะถูกฝึกด้วยข้อมูลจาก 9 ส่วน และทดสอบกับ 1 ส่วนที่เหลือ พร้อมทั้งมีการปรับจูนพารามิเตอร์ (Hyperparameter Tuning) ของแบบจำลอง Lasso Logistic Regression ด้วย GridSearchCV เพื่อหาค่าที่เหมาะสมที่สุด จากนั้นจะนำค่าประสิทธิภาพที่ได้จากทั้ง 10 รอบมาหาค่าเฉลี่ย เพื่อให้ได้ผลลัพธ์ที่น่าเชื่อถือและสะท้อนความสามารถที่แท้จริงของแบบจำลอง

3.5.5 การฝึกแบบจำลองบนข้อมูลทั้งหมดและพยากรณ์ (Final Training & Prediction) หลังจากประเมินผลสำเร็จแล้ว ผู้วิจัยได้นำแบบจำลองที่ผ่านการฝึกมาอย่างเหมาะสมที่สุด (best_model) ไปทำการฝึกซ้ำอีกครั้งบนชุดข้อมูลทั้งหมดที่ผ่านการทำความสะอาดและแปลงคุณลักษณะแล้ว เพื่อให้แบบจำลองได้เรียนรู้จากข้อมูลที่ครบถ้วนมากที่สุด จากนั้นจึงนำแบบจำลองนี้ไปพยากรณ์ความคิดเห็นทั้งหมด

ในชุดข้อมูล โดยสร้างคอลัมน์ใหม่ที่ชื่อ predicted_sentiment ซึ่งระบุประเภทของความรู้สึกที่แบบจำลองได้พยากรณ์ไว้ พร้อมสรุปจำนวนข้อความที่ถูกจัดประเภทในแต่ละประเภท (บวก, กลาง, ลบ)

3.6 การประเมินผลแบบจำลอง

การทดสอบบนชุดทดสอบและรายงานผล (Test Evaluation & Reporting) หลังจากได้แบบจำลองที่ดีที่สุดจากกระบวนการปรับพารามิเตอร์แล้ว ผู้วิจัยนำแบบจำลองดังกล่าวไปประเมินผลบนชุดทดสอบที่กันไว้ (X_test และ y_test) โดยใช้เมทริกซ์ประสิทธิภาพที่สำคัญ ได้แก่ ความแม่นยำ (Accuracy), ค่าความแม่นยำของแต่ละประเภท (Precision), การเรียกคืนข้อมูล (Recall), ค่าเฉลี่ยถ่วงน้ำหนัก (F1-Score) และแสดงผลลัพธ์ในรูปแบบ Confusion Matrix เพื่อสะท้อนให้เห็นถึงความสามารถของแบบจำลองในการจำแนกข้อความแต่ละประเภทของความรู้สึกอย่างชัดเจน

บทที่ 4
ผลการดำเนินงานวิจัย

ในงานวิจัยนี้ได้ทำการวิเคราะห์และจำแนกระดับความรู้สึก จำนวน 3 ระดับ (บวก, กลาง, ลบ) จากข้อความความคิดเห็นเกี่ยวกับโบรกเกอร์ จากพันทิป จำนวน 1327 ข้อความ โดยใช้เทคนิคการเรียนรู้ของเครื่อง (Machine Learning) ด้วยแบบจำลอง Lasso Logistic Regression ร่วมกับเทคนิคการประมวลผลภาษาธรรมชาติ (Natural Language Processing) ในการเตรียมความพร้อมของข้อมูลสำหรับแบบจำลอง โดยมีการจัดการข้อมูลที่ไม่สมดุลด้วยวิธี Under sampling และการแบ่งข้อมูล (หลังการทำ Under sampling ให้สมดุลที่ 909 ข้อความ) ออกเป็น ชุดข้อมูลฝึกฝน (Training Set) จำนวน 727 ข้อความ (80%) และชุดข้อมูลทดสอบ (Test Set) จำนวน 182 ข้อความ(20%) และมีการประเมินประสิทธิภาพของแบบจำลองที่ใช้ในงานวิจัย โดยให้เป็นไปตามวัตถุประสงค์ที่ได้กำหนดไว้ ดังนี้

4.1 ผลลัพธ์ของการแบ่งประเภทของข้อความ จำนวน 5 ประเภท จากข้อความของการแสดงความคิดเห็น ปัญหาทางระบบ ค่าธรรมเนียม การบริการ การเทรด และอื่น ๆ

4.2 ผลลัพธ์ของการประเมินประสิทธิภาพแบบจำลอง Lasso Logistic Regression ในการจำแนกความรู้สึก และ นำเสนอผลลัพธ์ในรูปแบบตาราง Confusion Matrix, Classification Report

4.3 ผลลัพธ์ของภาพรวมระดับความรู้สึกในแต่ละประเภทหัวข้อความคิดเห็น

4.1 ผลลัพธ์ของการแบ่งประเภทของข้อความ จำนวน 5 ประเภท จากข้อความของการแสดงความคิดเห็น ปัญหาทางระบบ ค่าธรรมเนียม การบริการ การเทรด และอื่น ๆ

การแบ่งประเภทของข้อความ จำนวน 5 ประเภท ซึ่งดำเนินการโดยใช้วิธี Rule-based keyword matching ผลการศึกษาจะแสดงให้เห็นถึงการกระจายตัวของจำนวนข้อความในแต่ละประเภท ดังรายละเอียดในตารางที่ 4.1

ประเภทข้อความ	จำนวนข้อความ	ร้อยละ
การเทรด	823	62.02
การบริการ	377	28.41
ปัญหาทางระบบ	87	6.56
ค่าธรรมเนียม	38	2.86
อื่น ๆ	2	0.15
รวม	1327	100

ตารางที่ 4.1 แสดงผลลัพธ์ของการแบ่งประเภทของข้อความ จำนวน 5 ประเภท ด้วย Rule-based keyword matching

ประเภทข้อความ	ตัวอย่างข้อความ
การบริการ	ผมก็เทรดของ TP trades อยู่ก็ดีเทรดได้ทั้ง forex และคริปโต บริการดีครับ
การเทรด	Dime เน้นให้รายย่อยสามารถซื้อขายหุ้นสหรัฐฯ ด้วยเงินจำนวนน้อย แตกต่างจากโบรกเกอร์อื่นที่มีขั้นต่ำสูงกว่า Dime ลงทุนได้หลายอย่าง หุ้นเมกา หุ้นไทย กองทุนรวมทั้งในไทยและต่างประเทศ ทองคำ เงินฝากสกุลเงินดอลลาร์

ตารางที่ 4.2 แสดงตัวอย่างการแบ่งประเภทข้อความ

จากผลการแบ่งประเภทข้อความแสดงความคิดเห็นทั้งหมด 1,327 ข้อความ (ดังแสดงในตารางที่ 4.1) ด้วยวิธีการ Rule-based keyword matching พบว่า ข้อความส่วนใหญ่ถูกจัดอยู่ในประเภท การเทรด ซึ่งมีจำนวนถึง 823 ข้อความ คิดเป็นร้อยละ 62.02 ของข้อความทั้งหมด รองลงมาคือประเภท การบริการ จำนวน 377 ข้อความ (ร้อยละ 28.41) ประเภท ปัญหาทางระบบ จำนวน 87 ข้อความ (ร้อยละ 6.56) ประเภท ค่าธรรมเนียม จำนวน 38 ข้อความ (ร้อยละ 2.86) และ ประเภท อื่น ๆ มีจำนวนน้อยที่สุด คือ 2 ข้อความ (ร้อยละ 0.15) จากผลลัพธ์ดังกล่าวชี้ให้เห็นว่าผู้ใช้งานพันทิปมักแสดงความคิดเห็นเกี่ยวกับประเด็นด้านการใช้งานระบบเทรดและการบริการมากที่สุด

4.2 ผลลัพธ์ของการประเมินประสิทธิภาพแบบจำลอง Lasso Logistic Regression ในการจำแนกความรู้สึก

หลังจากฝึกสอนแบบจำลอง Lasso Logistic Regression ด้วยชุดข้อมูลฝึกฝน (Training Set จำนวน 727 ข้อความ จากข้อมูลที่ผ่านการ Under sampling ทั้งหมด 909 ข้อความ) แล้ว ได้มีการนำแบบจำลองมาทดสอบกับชุดข้อมูลทดสอบ (Test Set จำนวน 182 ข้อความ) ซึ่งเป็นข้อมูลที่แบบจำลองไม่เคยพบเห็นมาก่อน เพื่อประเมินประสิทธิภาพในการจำแนกระดับความรู้สึก (ลบ, กลาง, บวก) ผลการประเมินโดยละเอียดถูกนำเสนอผ่านตาราง และรูปภาพดังต่อไปนี้

Sentiment	Precision	Recall	F1-score	Support
ลบ	0.64	0.71	0.67	49
กลาง	0.66	0.68	0.67	66
บวก	0.90	0.79	0.84	67

ตารางที่ 4.3 แสดงตาราง Classification Report การประเมินผลลัพธ์การทำนายตัวแบบ

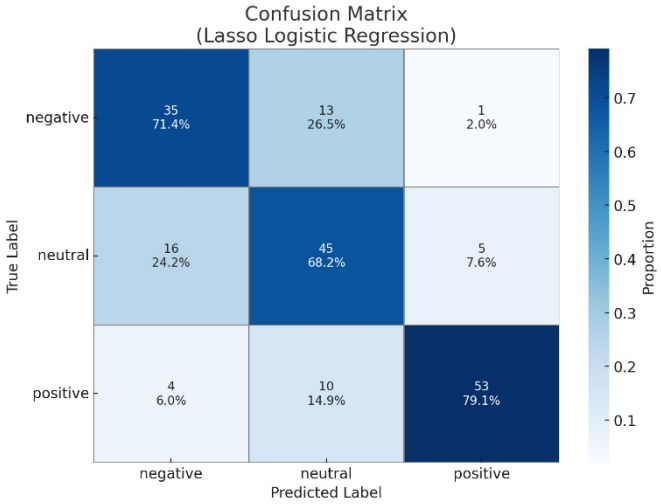

ภาพประกอบที่ 4.1 แสดงตาราง Confusion Matrix การประเมินผลลัพธ์การทำนายตัวแบบ

ผลการประเมินประสิทธิภาพของแบบจำลอง Lasso Logistic Regression บนชุดข้อมูลทดสอบ จำนวน 182 ข้อความ แสดงให้เห็นว่าแบบจำลองมีความแม่นยำโดยรวม ในการจำแนกระดับความรู้สึกอยู่ที่ 73.08% จากรายงานการจำแนกประเภท (Classification Report) พบว่าแบบจำลองมีประสิทธิภาพดีที่สุดในการจำแนกความคิดเห็นเชิงบวก โดยมีค่า Precision, Recall และ F1-score เท่ากับ 0.90, 0.79 และ 0.84 ตามลำดับ สำหรับความคิดเห็นเชิงลบ แบบจำลองให้ค่า Precision 0.64, Recall 0.71 และ F1-score 0.67 ส่วนความคิดเห็นกลางให้ค่า Precision 0.66, Recall 0.68 และ F1-score 0.67 ตามลำดับ เมื่อพิจารณาจากตาราง Confusion Matrix ซึ่งแสดงการทำนายเทียบกับค่าจริง (โดยลำดับประเภท คือ ลบ, กลาง, บวก ตามที่แสดงใน Classification Report) พบว่า สำหรับความคิดเห็นเชิงลบ 49 รายการ แบบจำลองทำนายถูกต้อง 35 รายการ โดยมีการทำนายผิดเป็นกลาง 13 รายการ และเป็นบวก 1 รายการ สำหรับความคิดเห็นที่เป็นกลาง 66 รายการ ทำนายถูกต้อง 45 รายการ โดยทำนายผิดเป็นลบ 16 รายการ และเป็นบวก 5 รายการ และสำหรับความคิดเห็นเชิงบวก 67 รายการ ทำนายถูกต้อง 53 รายการ โดยทำนายผิดเป็นลบ 4 รายการ และเป็นกลาง 10 รายการ

4.3 ระดับความรู้สึกในแต่ละประเภทหัวข้อความคิดเห็น

เพื่อทำความเข้าใจทัศนคติของผู้ใช้งานที่มีต่อแต่ละประเด็นการให้บริการของโบรกเกอร์อย่างลึกซึ้งยิ่งขึ้น งานวิจัยนี้ได้นำผลการจำแนกระดับความรู้สึก (บวก, กลาง, ลบ) ด้วยแบบจำลอง Lasso Logistic Regression มาวิเคราะห์ร่วมกับการแบ่งประเภทหัวข้อความคิดเห็นทั้ง 5 ประเภท (ปัญหาทางระบบ, ค่าธรรมเนียม, การบริการ, การเทรด, และอื่น ๆ) ผลการวิเคราะห์สัดส่วนร้อยละของระดับความรู้สึกในแต่ละประเภทหัวข้อหลักได้ถูกนำเสนอในรูปแบบของกราฟแท่ง ดังแสดงในภาพประกอบ 4.2-4.6 เพื่อให้เห็นภาพการกระจายตัวของความรู้สึกได้อย่างชัดเจน

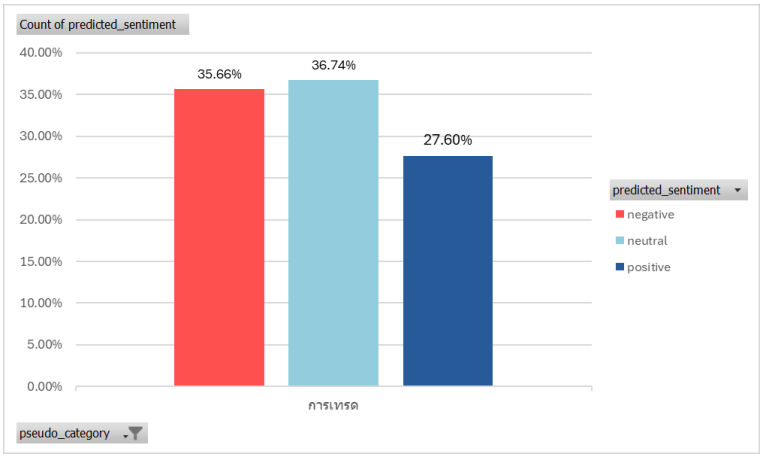

ภาพประกอบที่ 4.2 แสดงผลลัพธ์ด้านการเทรด

ด้านการเทรด (Trading) ความคิดเห็นในหัวข้อนี้มีการกระจายตัวของระดับความรู้สึกค่อนข้างใกล้เคียงกัน โดยพบความคิดเห็นที่เป็นกลาง (Neutral) มากที่สุดที่ประมาณ 36.74% ตามมาด้วยความคิดเห็นเชิงลบ (Negative) ประมาณ 35.66% และความคิดเห็นเชิงบวก (Positive) ประมาณ 27.60%

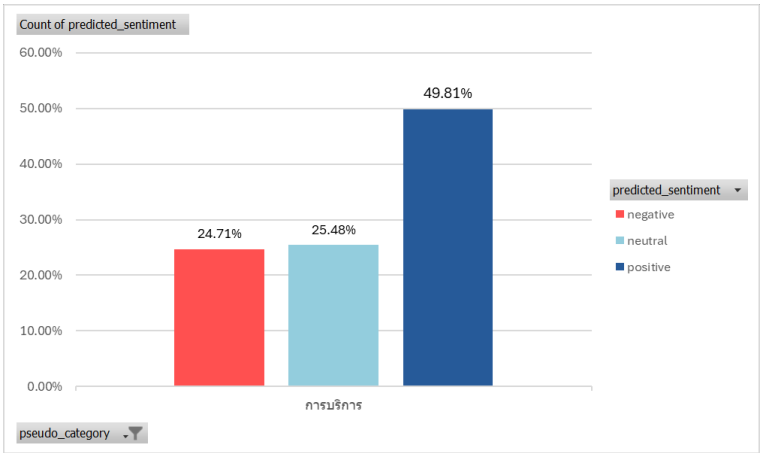

ภาพประกอบที่ 4.3 แสดงผลลัพธ์ด้านการบริการ

ด้านการบริการ (Service) ความคิดเห็นในหัวข้อนี้มีแนวโน้มเชิงบวกอย่างเห็นได้ชัด โดยความคิดเห็นเชิงบวก (Positive) มีสัดส่วนสูงถึงประมาณ 49.81% ในขณะที่ความคิดเห็นที่เป็นกลาง (Neutral) อยู่ที่ประมาณ 25.48% และความคิดเห็นเชิงลบ (Negative) อยู่ที่ประมาณ 24.71% แสดงให้เห็นว่าผู้ใช้งานส่วนใหญ่มีประสบการณ์ที่ดีหรือพึงพอใจกับการบริการที่ได้รับ

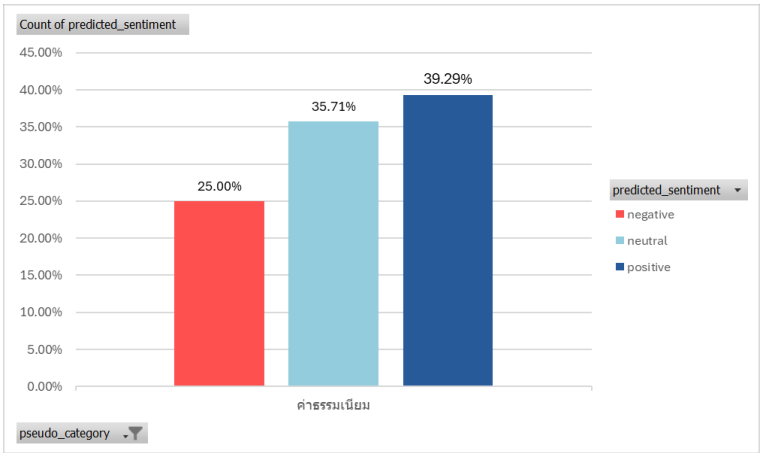

ภาพประกอบที่ 4.4 แสดงผลลัพธ์ด้านค่าธรรมเนียม

ด้านค่าธรรมเนียม (Fees) ในหัวข้อนี้ ความคิดเห็นเชิงบวก (Positive) มีสัดส่วนมากที่สุดที่ประมาณ 39.29% ตามมาด้วยความคิดเห็นที่เป็นกลาง (Neutral) ประมาณ 35.71% และความคิดเห็นเชิงลบ (Negative) ประมาณ 25.00% ชี้ให้เห็นว่าผู้ใช้งานส่วนหนึ่งอาจมองว่าค่าธรรมเนียมมีความสมเหตุสมผลหรือยอมรับได้

ภาพประกอบที่ 4.5 แสดงผลลัพธ์ด้านอื่นๆ

ด้านอื่น ๆ (Others) ความคิดเห็นที่ถูกจัดอยู่ในประเภทอื่น ๆ นั้น พบว่าเป็นความคิดเห็นเชิงลบ (Negative) ทั้งหมด 100.00% เนื่องจากจำนวนข้อความในประเภทนี้มีเพียง 2 ข้อความ

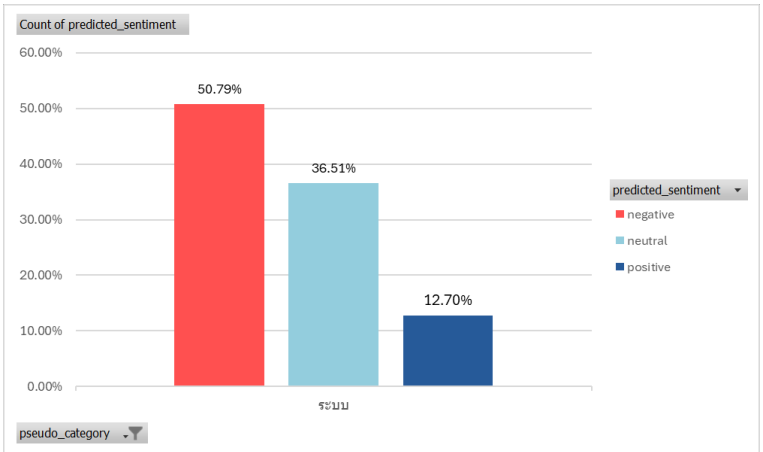

ภาพประกอบที่ 4.6 แสดงผลลัพธ์ด้านระบบ

ด้านปัญหาทางระบบ (System Issues) ความคิดเห็นในหัวข้อนี้มีแนวโน้มเชิงลบอย่างชัดเจน โดยความคิดเห็นเชิงลบ (Negative) มีสัดส่วนสูงที่สุดถึงประมาณ 50.79% รองลงมาคือความคิดเห็นที่เป็นกลาง (Neutral) 36.51% และความคิดเห็นเชิงบวก (Positive) มีสัดส่วนน้อยที่สุดเพียงประมาณ 12.70% ผลลัพธ์นี้บ่งชี้ว่าปัญหาทางระบบเป็นประเด็นสำคัญที่สร้างความไม่พอใจให้กับผู้ใช้งาน

บทที่ 5
สรุปผลการวิจัย อภิปรายผล และข้อเสนอแนะ

งานวิจัยนี้ได้ดำเนินการวิเคราะห์ข้อความแสดงความคิดเห็นภาษาไทยที่เกี่ยวข้องกับบริการของโบรกเกอร์ ซึ่งรวบรวมจากกระทู้บนเว็บไซต์ Pantip.com โดยมีเป้าหมายหลักเพื่อสามารถแบ่งประเภทของข้อความออกเป็น 5 ประเภทหลัก ได้แก่ ปัญหาทางระบบ, ค่าธรรมเนียม, การบริการ, การเทรด, และอื่น ๆ ด้วยวิธีการแบบอิงกฎ (Rule-based approach) นอกจากนี้ งานวิจัยยังมุ่งเน้นการพัฒนาและประเมินประสิทธิภาพของแบบจำลองการเรียนรู้ของเครื่อง (Machine Learning) สำหรับการจำแนกระดับความรู้สึก (บวก, กลาง, ลบ) ของข้อความที่เกี่ยวข้องกับโบรกเกอร์ ซึ่งผลการวิเคราะห์ที่ได้นี้คาดว่าจะเป็นประโยชน์ต่อผู้ให้บริการด้านการลงทุนและโบรกเกอร์ในการนำไปปรับปรุงและพัฒนากลยุทธ์การบริการให้ตอบโจทย์ความต้องการของผู้ใช้งานได้ดียิ่งขึ้น จากการดำเนินการวิเคราะห์ตามระเบียบวิธีวิจัยที่ได้ออกแบบไว้ สามารถสรุปผลการค้นพบที่สำคัญได้ดังต่อไปนี้

5.1 สรุปผลการวิจัย

5.1.1 ด้านการแบ่งประเภทหัวข้อความคิดเห็น จากการวิเคราะห์ข้อความแสดงความคิดเห็นทั้งหมด 1,327 ข้อความ ด้วยวิธีการแบบอิงกฎโดยใช้การจับคู่คำสำคัญ พบว่าสามารถจัดกลุ่มความคิดเห็นออกเป็น 5 ประเภทหลักได้สำเร็จ โดยประเด็นที่ผู้ใช้งานพันทิปกล่าวถึงมากที่สุดคือ การเทรด (62.02%) และ การบริการ (28.41%) ปัญหาทางระบบ (6.56%), ค่าธรรมเนียม (2.86%), และ อื่น ๆ (0.15) ตามลำดับ (รายละเอียดดังแสดงในตารางที่ 4.1) ผลลัพธ์นี้ชี้ให้เห็นว่าการเทรด และการให้บริการเป็นประเด็นหลักที่ผู้ใช้งานให้ความสนใจและแสดงความคิดเห็นมากที่สุด

5.1.2 ด้านการพัฒนาและประเมินประสิทธิภาพแบบจำลองการจำแนกความรู้สึก โดยใช้ แบบจำลอง Lasso Logistic Regression ที่พัฒนาขึ้นเพื่อจำแนกระดับความรู้สึก (บวก, กลาง, ลบ) จากข้อความที่ผ่านการแปลงเป็นคุณลักษณะด้วยเทคนิค TF-IDF แสดงให้เห็นถึงประสิทธิภาพในการจำแนกบนชุดข้อมูลทดสอบ (Test Set จำนวน 182 ข้อความ) โดยมีความแม่นยำโดยรวม อยู่ที่ประมาณ 73.08% เมื่อพิจารณาประสิทธิภาพรายประเภทจาก Classification Report (ดังแสดงในตารางที่ 4.3) แบบจำลองทำงานได้ดีที่สุดในการจำแนกความคิดเห็นเชิงบวก (F1-score 0.84) ตามมาด้วยความคิดเห็นเชิงลบ (F1-score 0.67) และความคิดเห็นที่เป็นกลาง (F1-score 0.67) นอกจากนี้ การวิเคราะห์ตาราง Confusion Matrix (ดังแสดงในรูปภาพที่ 4.1) พบว่าแบบจำลองมีความสามารถในการทำนายความคิดเห็น เชิงลบ ได้ถูกต้อง 35 จาก 49 รายการ, ทำนายความคิดเห็น ที่เป็นกลาง ถูกต้อง 45 จาก 66 รายการ, และทำนายความคิดเห็น เชิงบวก ถูกต้อง 53 จาก 67 รายการ

5.1.3 ภาพรวมระดับความรู้สึกในแต่ละประเภทหัวข้อความคิดเห็น จากการวิเคราะห์สัดส่วนความรู้สึกในแต่ละประเภทหัวข้อหลักพบว่า ผู้ใช้งานแสดงความรู้สึกเชิงลบในประเด็น ปัญหาทางระบบ, อื่น ๆ

และ แสดงความรู้สึก เชิงบวก ในประเด็น การบริการ, ค่าธรรมเนียม และสำหรับประเด็น การเทรดระดับความรู้สึกมีการกระจายตัวค่อนข้างหลากหลาย

5.2 อภิปรายผลการวิจัย

ผลการวิเคราะห์ที่ได้นำเสนอในบทที่ 4 ซึ่งครอบคลุมทั้งการแบ่งประเภทหัวข้อความคิดเห็นและการจำแนกระดับความรู้สึกของผู้ใช้งานโบรกเกอร์บน Pantip.com ได้ให้ข้อมูลเชิงลึกที่สำคัญหลายประการซึ่งสามารถนำมาอภิปรายเพื่อทำความเข้าใจความหมายและนัยยะของผลลัพธ์ได้อย่างละเอียด ดังนี้

ประการแรก การกระจายตัวของประเภทหัวข้อความคิดเห็น พบว่าผู้ใช้งานให้ความสนใจและแสดงความคิดเห็นเกี่ยวกับประเด็น การเทรด (62.02%) และ การบริการ (28.41%) เป็นสัดส่วนที่สูงที่สุด สะท้อนให้เห็นว่าประสบการณ์ในการใช้งานระบบเทรดและคุณภาพของการบริการลูกค้าเป็นปัจจัยหลักที่ผู้ใช้งานให้ความสำคัญ และมีประสบการณ์โดยตรงมากที่สุดเมื่อมีปฏิสัมพันธ์กับโบรกเกอร์ สำหรับวิธีการแบบอิงกฎ (Rule-based keyword matching) ที่ใช้ในการจำแนกประเภทหัวข้อทั้ง 5 ประเภท แม้จะมีความตรงไปตรงมาในการพัฒนาและตีความผลลัพธ์ แต่ก็อาจมีข้อจำกัดในด้านความยืดหยุ่นในการจัดการกับรูปแบบภาษาที่หลากหลายหรือคำศัพท์ใหม่ ๆ ที่ไม่ได้อยู่ในชุดคำสำคัญที่กำหนดไว้ อย่างไรก็ตาม การที่สามารถแยกแยะประเด็นหลักที่ผู้ใช้งานกล่าวถึงได้สำเร็จนั้นถือเป็นข้อมูลเบื้องต้นที่สำหรับโบรกเกอร์ในการระบุจุดที่ต้องการการดูแลเป็นพิเศษ

ประการที่สอง ประสิทธิภาพของแบบจำลอง Lasso Logistic Regression ในการจำแนกความรู้สึก ค่าความแม่นยำโดยรวมที่ 73.08% และค่า F1-score โดยรวม (Macro Avg 0.73) แสดงให้เห็นว่าแบบจำลองที่พัฒนาขึ้นสามารถจำแนกความรู้สึกจากข้อความภาษาไทยได้ในระดับที่ น่าพอใจในระดับหนึ่ง และสามารถให้ข้อมูลเบื้องต้นที่เป็นประโยชน์ได้ การที่แบบจำลองมีประสิทธิภาพในการจำแนกความคิดเห็น เชิงบวก (F1-score 0.84 และ Precision สูงถึง 0.90) ได้ดีที่สุด อาจเนื่องมาจากลักษณะภาษาที่ชัดเจน ในขณะที่ความคิดเห็น เชิงลบ (F1-score 0.67) และ ที่เป็นกลาง (F1-score 0.67) มีประสิทธิภาพต่ำกว่า ซึ่งอาจบ่งชี้ถึงความกำกวมของภาษาที่ใช้ หรือความท้าทายในการแยกแยะความรู้สึกทั้งสองกลุ่มนี้ออกจากกัน และออกจากกลุ่มเชิงบวก

ประการสุดท้าย นัยสำคัญของผลการวิเคราะห์ระดับความรู้สึกในแต่ละประเภทหัวข้อต่อผู้ให้บริการโบรกเกอร์ (ดังแสดงในภาพประกอบที่ 4.5-4.9, หน้า 28-30 ของรูปเล่ม) ได้ให้ข้อมูลเชิงลึกที่มีคุณค่าอย่างยิ่ง การที่หัวข้อ ปัญหาทางระบบ แสดงความรู้สึก เชิงลบเด่นชัด (50.79%) เป็นสัญญาณเตือนที่สำคัญให้โบรกเกอร์ต้องเร่งตรวจสอบและแก้ไขปัญหาดังกล่าว ในทางตรงกันข้าม การที่หัวข้อ การบริการ ได้รับผลตอบรับเชิงบวกเป็นส่วนใหญ่ (49.81%) ชี้ให้เห็นถึงจุดแข็งที่ควรส่งเสริม สำหรับหัวข้อ การเทรดที่มีความคิดเห็นกระจายตัว (กลาง 36.74%, ลบ 35.66%, บวก 27.60%) บ่งชี้ว่าอาจมีทั้งแง่มุมที่ผู้ใช้พึงพอใจและไม่พึงพอใจปะปนกัน จำเป็นต้องมีการวิเคราะห์ในรายละเอียดเพิ่มเติม โดยรวมแล้ว ผลการวิจัยนี้ได้มอบเครื่องมือและข้อมูลเชิงลึกที่สามารถช่วยให้ผู้ให้บริการด้านการลงทุนและโบรกเกอร์ได้เข้าใจ "เสียงของลูกค้า"

(Voice of Customer) ได้ดียิ่งขึ้น เพื่อนำไปวิเคราะห์และวางกลยุทธ์พัฒนาบริการให้ตอบโจทย์ความต้องการของผู้ใช้งานอย่างแท้จริง ซึ่งสอดคล้องกับประโยชน์ข้อที่ 3 ของงานวิจัย

5.3 ข้อเสนอแนะ

จากผลการวิจัยที่ได้อภิปรายมาข้างต้น รวมถึงข้อจำกัดที่พบในกระบวนการดำเนินงาน สามารถให้ข้อเสนอแนะเพื่อการนำผลการวิจัยไปประยุกต์ใช้และเพื่อการพัฒนางานวิจัยในอนาคตได้ดังนี้

5.3.1 ข้อมูลที่ทำในงานวิจัยมีจำนวนที่น้อยเกินไปในการฝึกฝนแบบจำลอง หากสามารถเพิ่มจำนวนข้อมูล หรือเก็บข้อมูลจากแหล่งอื่น ๆเพิ่มได้ อาจทำให้ประสิทธิภาพของแบบจำลองเพิ่มมากขึ้น

5.3.2 วิธีการ Rule-based keyword matching ในการแบ่งหัวข้อทั้ง 5 ประเภท ยังมีข้อจำกัดในด้านความแม่นยำหรือความยืดหยุ่น อาจพิจารณาการใช้เทคนิคการเรียนรู้ของเครื่องสำหรับการจำแนกหลายหมวดหมู่ (Multi-class Text Classification) เพื่อเพิ่มประสิทธิภาพในการจัดกลุ่มหัวข้อ

5.3.3 ควรพิจารณาการทดลองใช้เทคนิค Feature Engineering อื่น ๆ (Word Embeddings, Pre-trained Language Models) รวมถึง การทดลองแบบจำลอง Machine Learning หรือ Deep Learning อื่น ๆ (SVM, Random Forest, RNN, Transformers) เพื่อเพิ่มความแม่นยำในการจำแนกความรู้สึก

5.3.4 พัฒนากระบวนการทั้งหมดให้เป็นระบบอัตโนมัติที่สามารถทำงานได้อย่างต่อเนื่อง เพื่อให้ผู้ให้บริการโบรกเกอร์สามารถติดตามความคิดเห็นของลูกค้าได้แบบใกล้เคียงเรียลไทม์

เอกสารอ้างอิง

1. Batool, S., Zulkiffal, M., Abbas, G., Hammad, M., Zahra, S., Shah, S. M. A., Shahzad, K., Asif, M., Mehmood, K., & Khalid, M. H. B. (2024). Genetic divergence, trait association, and path coefficient analysis for morpho-physiological and yield-related traits in wheat (Triticum aestivum L.) under drought stress conditions. *Pakistan Journal of Life and Social Sciences, 22*(2), 3330–3350. https://pjlss.edu.pk/pdf_files/2024_2/3330-3350.pdf
2. Grassi, S. (2025). Sentiment classification of Thai Central Bank press releases using supervised learning [Preprint]. *arXiv*. https://arxiv.org/abs/2503.22629
3. James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An Introduction to Statistical Learning: With Applications in R*. Springer. https://doi.org/10.1007/978-1-0716-1418-1
4. Padhanarath, P., Aunhathaweesup, Y., & Kiattisin, S. (2019). Sentiment analysis and relationship between social media and stock market: pantip.com and SET. *IOP Conference Series: Materials Science and Engineering, 620*, Article 012094. https://doi.org/10.1088/1757-899X/620/1/012094
5. Zhang, Z., Rosen-Zvi, M., Rosen, G. L., & Cole, B. (2024). BioCoder: A benchmark for bioinformatics code generation with large language models [Preprint]. *arXiv*. https://arxiv.org/abs/2412.06837
6. ชวิศ ภูมผา. (2015). การพัฒนาและหาประสิทธิภาพบทเรียนคอมพิวเตอร์ช่วยสอน เรื่อง การสร้างเว็บเพจด้วยภาษา HTML สำหรับนักเรียนชั้นมัธยมศึกษาปีที่ 2 [วิทยานิพนธ์ปริญญามหาบัณฑิต, มหาวิทยาลัยราชภัฏอุบลราชธานี]. https://www.esanpedia.oar.ubu.ac.th/e-research/sites/default/files/Chawit_Phoomphana.pdf
7. ธนภรณ์ สีชาลี & ศรัญญา กัญจนวัฒนา. (2022). การเปรียบเทียบประสิทธิภาพของแบบจำลองการพยากรณ์อนุกรมเวลาสำหรับการพยากรณ์ราคาผลปาล์มทะลาย. *วารสารวิชาการพระจอมเกล้าพระนครเหนือ, 15*(4), 677–691. https://ph01.tci-thaijo.org/index.php/kmutnb-journal/article/view/257882/172620
8. พิเชษฎ์ จุลรอด & ดินสอ บุญมา. (2023). การวิเคราะห์ความรู้สึกของผู้บริโภคและใช้บริการร้านอาหารและร้านค้าในมหาวิทยาลัยเชียงใหม่. *วารสารสารสนเทศศาสตร์ มหาวิทยาลัยเชียงใหม่, 1*(1), 73–83.
9. พิศิษฐ์ บวรเลิศสุธี & วรภัทร ไพรีเกรง. (2022). การวิเคราะห์ความรู้สึกทางอารมณ์ในบทความแนะนำสินค้าออนไลน์. *วารสารวิจัย มหาวิทยาลัยเทคโนโลยีราชมงคลศรีวิชัย, 14*(3), 755–769.

10. ภานุวัฒน์ ศรีระโรจน์ & จิรัชญา คัมภิรานนท์. (2022). การพัฒนาระบบแนะนำสถานที่ท่องเที่ยวในจังหวัดสตูลด้วยเทคนิคการกรองเนื้อหาร่วมกับการเรียนรู้ของเครื่อง. *วารสารวิทยาศาสตร์และเทคโนโลยีสารสนเทศ, 11*(1), 31–43. https://ph02.tci-thaijo.org/index.php/JIST/article/view/253881/171666

ภาคผนวก ก

การวิเคราะห์ความรู้สึกข้อความภาษาไทยที่มีต่อบริการของโบรกเกอร์
จากกระทู้พันทิปโดยใช้เทคนิคการเรียนรู้ของเครื่อง

```
import os
import time
import re
import emoji
import pandas as pd
import numpy as np
import pythainlp
from pythainlp.util import normalize
from pythainlp.tokenize import word_tokenize
from pythainlp.corpus.common import thai_stopwords
from selenium import webdriver
from selenium.webdriver.common.by import By
from selenium.webdriver.chrome.options import Options
from selenium.webdriver.chrome.service import Service
from selenium.webdriver.support.ui import WebDriverWait
from selenium.webdriver.support import expected_conditions as EC
from webdriver_manager.chrome import ChromeDriverManager
from sklearn.model_selection import (train_test_split, GridSearchCV, StratifiedKFold,
cross_val_predict)
from sklearn.feature_extraction.text import TfidfVectorizer
from sklearn.linear_model import LogisticRegression
from sklearn.preprocessing import LabelEncoder
from sklearn.metrics import (classification_report, accuracy_score, confusion_matrix)
from sklearn.base import clone
from imblearn.over_sampling import SMOTE
from wordcloud import WordCloud
import matplotlib.pyplot as plt
import matplotlib.font_manager as fm
from collections import Counter
import pickle
from nltk.corpus import stopwords as sw
```

```
def scrape_topic(url):
    """
    ดึงข้อมูลจากกระทู้ Pantip
    คืนค่าเป็น DataFrame ที่มีคอลัมน์:
      topic_url, thread_title, tags, author, comment
    โดย:
      - thread_title: หัวข้อกระทู้ (จาก h1, h2 หรือ fallback)
      - tags: ข้อความแท็กของกระทู้ (ดึงจาก element ที่มีคลาส "tag-item")
      - author, comment: ดึงจาก element ที่มีคลาส "display-post-name" และ "display-post-story"
    """
    options = Options()
    options.add_argument("--headless")
    options.add_argument("--no-sandbox")
    options.add_argument("--disable-dev-shm-usage")
    options.add_argument("--disable-gpu")  # เพิ่มเพื่อป้องกันปัญหา GPU
    # ตั้งค่า user-agent ให้เหมือนเบราว์เซอร์จริง
    options.add_argument("user-agent=Mozilla/5.0 (Windows NT 10.0; Win64; x64) "
                         "AppleWebKit/537.36 (KHTML, like Gecko) "
                         "Chrome/115.0.0.0 Safari/537.36")

    service = Service(ChromeDriverManager().install())
    driver = webdriver.Chrome(service=service, options=options)

    # ตั้งค่า Timeout ให้สูงขึ้น
    driver.set_page_load_timeout(60)
    driver.set_script_timeout(60)

    driver.get(url)
    try:
        WebDriverWait(driver, 10).until(
            EC.presence_of_element_located((By.CLASS_NAME, "display-post-story"))
        )
```

```
except Exception as e:
    print(f"[DEBUG] Timeout waiting for comments in {url}: {e}")
time.sleep(2)

# ดึงหัวข้อกระทู้: ลองหา h1 ก่อน ถ้าไม่เจอให้หา h2
try:
    thread_title = driver.find_element(By.TAG_NAME, "h1").text.strip()
except Exception:
    try:
        thread_title = driver.find_element(By.TAG_NAME, "h2").text.strip()
    except Exception:
        thread_title = ""

# ดึงแท็กของกระทู้: คาดว่าอยู่ใน element ที่มีคลาส "tag-item"
try:
    tag_elements = driver.find_elements(By.CLASS_NAME, "tag-item")
    tags = [tag.text.strip() for tag in tag_elements]
except Exception as e:
    print(f"[DEBUG] ไม่สามารถดึงแท็กได้จาก {url}: {e}")
    tags = []

# เลื่อนหน้าจอหลายครั้งเพื่อให้โหลดคอมเมนต์ (ลดเวลาการ sleep)
for _ in range(5):
    driver.execute_script("window.scrollTo(0, document.body.scrollHeight);")
    time.sleep(1)

try:
    WebDriverWait(driver, 10).until(
        EC.presence_of_all_elements_located((By.CLASS_NAME, "display-post-story"))
    )
except Exception:
    pass
```

```
    # ดึงคอมเมนต์และชื่อผู้โพสต์
    authors = driver.find_elements(By.CLASS_NAME, "display-post-name")
    comments = driver.find_elements(By.CLASS_NAME, "display-post-story")

    print(f"[DEBUG] {url} พบ authors = {len(authors)}, comments = {len(comments)}")

    all_data = []
    for author, comment in zip(authors, comments):
        all_data.append({
            "topic_url": url,
            "thread_title": thread_title,
            "tags": ", ".join(tags),
            "author": author.text.strip(),
            "comment": comment.text.strip()
        })

    driver.quit()
    return pd.DataFrame(all_data)

def main():
    input_csv = "pantip_comments_krungthai.csv"  # ไฟล์ CSV ที่มีลิงก์กระทู้ (คอลัมน์ "topic_url")
    output_csv = "pantip_comments_all_กท.csv"       # ไฟล์สำหรับเก็บข้อมูลที่ดึงได้

    if not os.path.exists(input_csv):
        print(f"ไม่พบไฟล์ {input_csv}")
        return

    df_links = pd.read_csv(input_csv)
    if "topic_url" not in df_links.columns:
        print(f"ไฟล์ {input_csv} ต้องมีคอลัมน์ 'topic_url'")
        return
```

```
    # ดึงลิงก์จากคอลัมน์ topic_url ทั้งหมด
    link_list = df_links["topic_url"].dropna().tolist()
    if not link_list:
        print("ไม่พบลิงก์ในไฟล์")
        return

    if os.path.exists(output_csv):
        existing_df = pd.read_csv(output_csv)
    else:
        existing_df = pd.DataFrame(columns=["topic_url", "thread_title", "tags", "author",
"comment"])

    new_dfs = []
    # วนลูปดึงข้อมูลจากทุกลิงก์ (จนครบทุกลิงก์)
    for new_url in link_list:
        new_url = new_url.strip()
        if not new_url:
            continue
        print(f"กำลังดึงข้อมูลจาก: {new_url}")
        try:
            df_topic = scrape_topic(new_url)
            new_dfs.append(df_topic)
        except Exception as e:
            print(f"เกิดข้อผิดพลาดในการดึงข้อมูลจาก {new_url}: {e}")

    if new_dfs:
        new_data = pd.concat(new_dfs, ignore_index=True)
    else:
        new_data = pd.DataFrame(columns=["topic_url", "thread_title", "tags", "author",
"comment"])
```

```
    combined_df = pd.concat([existing_df, new_data], ignore_index=True)

    combined_df["clean_topic_url"] = combined_df["topic_url"].str.strip().str.rstrip("/")
    combined_df.drop_duplicates(subset=["clean_topic_url", "thread_title", "tags", "author",
"comment"], inplace=True)

    combined_df.to_csv(output_csv, index=False, encoding="utf-8-sig")

    unique_topics = combined_df["clean_topic_url"].unique()
    print(f"บันทึกข้อมูลลงไฟล์ {output_csv} แล้ว! มีคอมเมนต์ทั้งหมด {len(combined_df)} แถว จาก
{len(unique_topics)} กระทู้")

    print("\nตัวอย่างข้อมูลที่ดึงได้:")
    print(combined_df.head())

if __name__ == "__main__":
    main()
```

```
# เติมค่าว่างแทน NaN
df['comment'] = df['comment'].fillna('')
# STEP 0: ต้นฉบับ
df['step0_original'] = df['comment']
# STEP 1: demojize
df['step1_demojize'] = df['step0_original'].apply(lambda t: emoji.demojize(t))
# STEP 2: ลบ ? . ; : ! " ๆ ฯ
df['step2_no_punct'] = df['step1_demojize']\
    .apply(lambda t: "".join(ch for ch in t if ch not in ("?",".",";",":","!","'","ๆ","ฯ")))
# STEP 3: ลบ URL (http/https/www)
df['step3_no_url'] = df['step2_no_punct']\
    .apply(lambda t: re.sub(r'https?://\S+|www\.\S+', ' ', t))
# STEP 4: ลบ mention @username
df['step4_no_mention'] = df['step3_no_url']\
    .apply(lambda t: re.sub(r'@\w+', ' ', t))
# STEP 5: เก็บแค่ ก-๙, A-Za-z, 0-9, space
df['step5_alnum'] = df['step4_no_mention']\
    .apply(lambda t: re.sub(r'[^ก-๙A-Za-z0-9\s]', ' ', t))
# STEP 6: เว้นวรรคทุกตัวอักษร
df['step6_char_spaced'] = df['step5_alnum']\
    .apply(lambda t: " ".join(t))
# STEP 7: ลบ stopwords ไทย (ระดับอักขระ)
thai_stops = set(thai_stopwords())
df['step7_no_thai_stop'] = df['step6_char_spaced']\
    .apply(lambda t: "".join(ch for ch in t.split() if ch not in thai_stops))
# STEP 8: ตัดคำด้วย newmm
df['step8_tokenized'] = df['step7_no_thai_stop']\
    .apply(lambda t: pythainlp.word_tokenize(t, engine='newmm'))
# STEP 9: join tokens กลับเป็นสตริง
df['step9_joined'] = df['step8_tokenized']\
    .apply(lambda toks: " ".join(toks))
# STEP 10: ลบอักขระที่เกิน pattern สุดท้าย
```

```
df['comment_clean'] = df['step9_joined']\
    .apply(lambda t: re.sub(r'[^A-Za-zก-๙]+', ' ', t).strip())
print("ตัวอย่างข้อความที่ผ่านการทำความสะอาด:")
df

mapping = {'บวก':'positive', 'กลาง':'neutral', 'ลบ':'negative'}
df['sentiment'] = df['sentiment'].replace(mapping)

thai_fonts = [f for f in fm.findSystemFonts()
              if any(n in os.path.basename(f).lower() for n in ['thsarabun','leelawadee','angsana'])]
font_path = thai_fonts[0]

def plot_wordcloud_from_freq(freq_dict, title):
    wc = WordCloud(
        font_path=font_path,
        width=800, height=400,
        background_color='white',
        collocations=False
    ).generate_from_frequencies(freq_dict)
    plt.figure(figsize=(10,5))
    plt.imshow(wc, interpolation='bilinear')
    plt.axis('off')
    plt.title(title, fontsize=20)
    plt.show()

# --- เตรียม Counter สำหรับแต่ละคลาส ---
for label in ['positive','neutral','negative']:
    # 1) เก็บ list ของคำแต่ละข้อความ
    words = []
    for doc in df.loc[df['sentiment']==label, 'comment_clean']:
        # แยกตาม space (แต่ละ doc ต้องผ่านการ tokenized มาแล้ว)
        words.extend(doc.split())
```

```
    # 2) สร้างความถี่
    freq = Counter(words)
    # 3) plot
    plot_wordcloud_from_freq(freq, f"Word Cloud: {label}")

technical_keywords = {"ระบบล่ม", "ช้า", "error", "บัค", "ปัญหา", "เชื่อมต่อ"}
fee_keywords = {"ค่าสมัคร", "ค่าธรรมเนียม", "คอมมิชชั่น", "สเปรด", "spread"}
service_keywords = {"บริการ", "ลูกค้าสัมพันธ์", "ซัพพอร์ต", "ช่วยเหลือ", "แพลตฟอร์ม", "แอป",
"สอบถาม","แจ้ง","ข้อมูล","มือถือ", "ฝาก", "ถอน", }
trading_keywords = {"เทรด", "ซื้อขาย", "หุ้น", "order", "execution", "เลเวอเรจ", "trade", "brokerage",
"ราคา","พอร์ต","ปริมาณ","สัญญาณ", "ตลท", "ตลาดหลักทรัพย์", "forex", "โอนหลักทรัพย์"}
review_keywords = {"แนะนำ", "รีวิว", "ข้อเสนอแนะ", "คำแนะนำ","โปรโมชั่น","วิเคราะห์","ข้อเสนอ",
"เลือก", "ดู", "แนะนำ"}

# ----- ส่วนที่ 2: ฟังก์ชันจำแนกหมวดหมู่เบื้องต้น -----
def assign_category(text):
    text_lower = str(text).lower()
    if any(kw.lower() in text_lower for kw in technical_keywords):
        return "ระบบ"
    elif any(kw.lower() in text_lower for kw in fee_keywords):
        return "ค่าธรรมเนียม"
    elif any(kw.lower() in text_lower for kw in service_keywords):
        return "การบริการ"
    elif any(kw.lower() in text_lower for kw in trading_keywords):
        return "การเทรด"
    elif any(kw.lower() in text_lower for kw in review_keywords):
        return "รีวิว/คำแนะนำ"
    else:
        return "อื่นๆ"

# ----- ส่วนที่ 3: สร้าง pseudo labels -----
df['pseudo_category'] = df['comment_clean'].apply(assign_category)
```

```
# ----- ส่วนที่ 4: แปลง labels เป็นตัวเลข -----
le = LabelEncoder()
y_cat_encoded = le.fit_transform(df['pseudo_category'])

# ----- ส่วนที่ 5: แปลงข้อความเป็น TF-IDF features -----
tfidf_vectorizer_cat = TfidfVectorizer()
X_cat = tfidf_vectorizer_cat.fit_transform(df['comment_clean'])

# ----- ตรวจสอบผลลัพธ์ -----
print("การกระจาย pseudo_category:")
print(df['pseudo_category'].value_counts())
print(f"\nขนาดเมทริกซ์ features: {X_cat.shape}")
print(f"จำนวน labels: {len(y_cat_encoded)}")

df_positive = df[df['sentiment'] == 'positive']
df_negative = df[df['sentiment'] == 'negative']
df_neutral = df[df['sentiment'] == 'neutral']

# Calculate the minimum count among all sentiment categories
min_count = min(len(df_positive), len(df_negative), len(df_neutral))

# Sample from each category using the minimum count
df_negative_balanced = df_negative.sample(n=min_count, replace=False, random_state=42)
# Added replace=False and random_state for reproducibility
df_neutral_balanced = df_neutral.sample(n=min_count, replace=False, random_state=42)
df_positive_balanced = df_positive.sample(n=min_count, replace=False, random_state=42)
# Sample from df_positive as well

# Concatenate the balanced DataFrames
df_model = pd.concat([df_positive_balanced, df_negative_balanced,
df_neutral_balanced]).reset_index(drop=True)
```

```
print("จำนวนตัวอย่าง:", len(df_model))
print(df_model['sentiment'].value_counts())

X = df_model['comment_clean']
y = df_model['sentiment']

le = LabelEncoder()
y_encoded = le.fit_transform(y)
print("Sentiment classes :", le.classes_)
X_train, X_test, y_train, y_test = train_test_split(X, y_encoded, test_size=0.2)
print("Training samples:", X_train.shape[0], "Test samples:", X_test.shape[0])
tfidf_vectorizer = TfidfVectorizer(max_features=5000, ngram_range=(1,3))
X_train_tfidf = tfidf_vectorizer.fit_transform(X_train)
X_test_tfidf = tfidf_vectorizer.transform(X_test)
print("Vocabulary Size (TF-IDF):", len(tfidf_vectorizer.vocabulary_))

lasso_logistic = LogisticRegression(penalty='l1', solver='saga', max_iter=6000)
param_grid = {"C": [0.0001, 0.001, 0.01, 0.1, 1, 10, 100, 1000]}
skf = StratifiedKFold(n_splits=10, shuffle=True,)

grid = GridSearchCV(lasso_logistic, param_grid, cv=skf, scoring='f1_macro', n_jobs=-1)
grid.fit(X_train_tfidf, y_train)
print("\nLasso Logistic Regression ")
print("Best Parameters:", grid.best_params_)
print("Best CV F1_macro Score:", grid.best_score_)
best_model = grid.best_estimator_
```

```
X_full = tfidf_vectorizer.transform(df_model['comment_clean'])
y_full = le.transform(df_model['sentiment'])

skf_full = StratifiedKFold(n_splits=10, shuffle=True)
fold = 1
accuracy_list = []

for train_idx, test_idx in skf_full.split(X_full, y_full):
    X_cv_train = X_full[train_idx]
    y_cv_train = y_full[train_idx]
    X_cv_test  = X_full[test_idx]
    y_cv_test  = y_full[test_idx]

    # ใช้ clone เพื่อสร้างสำเนาของโมเดลที่ดีที่สุดสำหรับแต่ละ fold
    model_cv = clone(best_model)
    model_cv.fit(X_cv_train, y_cv_train)
    y_cv_pred = model_cv.predict(X_cv_test)
    acc_fold = accuracy_score(y_cv_test, y_cv_pred)
    print(f"Fold {fold} Accuracy: {acc_fold:.4f}")
    accuracy_list.append(acc_fold)
    fold += 1

mean_accuracy = np.mean(accuracy_list)
print("\nMean CV Accuracy (Loop):", mean_accuracy)
```

```
y_pred = best_model.predict(X_test_tfidf)
acc = accuracy_score(y_test, y_pred)
print("\nTest Accuracy:", acc)
print("\nClassification Report on Test Set:")
print(classification_report(y_test, y_pred, target_names=le.classes_, zero_division=0))
print("Confusion Matrix on Test Set:")
print(confusion_matrix(y_test, y_pred))

cm = confusion_matrix(y_test, y_pred)
cm_norm = cm.astype('float') / cm.sum(axis=1)[:, np.newaxis]
classes = le.classes_

fig, ax = plt.subplots(figsize=(7,7))
im = ax.imshow(cm_norm, interpolation='nearest')

cbar = fig.colorbar(im, ax=ax)
cbar.ax.set_ylabel('Proportion', rotation=-90, va="bottom")

ax.set_xticks(np.arange(len(classes)))
ax.set_yticks(np.arange(len(classes)))
ax.set_xticklabels(classes)
ax.set_yticklabels(classes)
plt.setp(ax.get_xticklabels(), rotation=45, ha="right")

for i in range(len(classes)):
    for j in range(len(classes)):
        count = cm[i, j]
        pct = cm_norm[i, j] * 100
        ax.text(j, i, f"{count}\n{pct:.1f}%",
                ha="center", va="center")

ax.set_xlabel('Predicted Label')
```

```
ax.set_ylabel('True Label')
ax.set_title('Confusion Matrix\n(Lasso Logistic Regression)')
plt.tight_layout()
plt.show()

best_model.fit(tfidf_vectorizer.transform(df_model['comment_clean']),
le.transform(df_model['sentiment']))
df_model['predicted_sentiment'] =
best_model.predict(tfidf_vectorizer.transform(df_model['comment_clean']))
df_model['predicted_sentiment'] = le.inverse_transform(df_model['predicted_sentiment'])
print(df_model['predicted_sentiment'].value_counts())
```